



AGH

**AKADEMIA GÓRNICZO-HUTNICZA
IM. STANISŁAWA STASZICA W KRAKOWIE**

WYDZIAŁ ZARZĄDZANIA

Katedra Zastosowań Matematyki w Ekonomii

PROJEKT DYPLOMOWY LICENCJACKI

***Zastosowanie metod uczenia maszynowego do prognozowania
zmienności kursów akcji wybranych spółek***

***Application of machine learning methods to forecast the volatility
of share prices of selected companies***

Autor: Zuzanna Pliszka

Kierunek studiów: Informatyka i Ekonometria

Opiekun pracy: dr hab. Łukasz Lach

Spis treści

Wstęp	4
1. Przegląd literatury	6
2. Zmienność cen akcji w sektorze bankowym – dane i struktura analizy	11
2.1. Znaczenie zmienności w ocenie kondycji sektora bankowego	11
2.2. Dobór próby badawczej	12
2.2.1. Indeks WIG-Banki	12
2.2.2. Spółka PKO Bank Polski	13
2.2.3. Uzasadnienie wyboru zestawu danych	14
2.3. Segmentacja czasowa danych według kluczowych wydarzeń rynkowych	14
2.4. Proces przygotowania danych i konstrukcja zmiennych	17
2.4.1. Oczyszczanie danych i przygotowanie do analizy	17
2.4.2. Konstrukcje zmiennych	17
2.5. Charakterystyka zmienności w ujęciu wstępnym	19
3. Teoretyczne podstawy modeli	24
3.1. Model GARCH	24
3.2. LSTM	26
3.3. XGBoost	30
3.4. Model hybrydowy – GARCH-GRU	32
3.5. Metody oceny jakości prognoz	35
4. Realizacja eksperymentu empirycznego z wykorzystaniem modeli prognostycznych	37
4.1. Implementacja modelu GARCH(1,1)	37
4.2. Implementacja modelu LSTM	40
4.3. Implementacja modelu XGBoost	46
4.4. Implementacja modelu GARCH-GRU	53
5. Ewaluacja i porównanie skuteczności modeli prognostycznych	60
5.1. Analiza porównawcza wyników	60
5.2. Porównanie wyników pracy z wnioskami z literatury przedmiotu	70
5.3. Wnioski końcowe	71
Podsumowanie	73

Bibliografia	74
Źródła internetowe	76
Spis Rysunków	77
Spis tabel.....	79
Spis załączników.....	82

Wstęp

Współczesne rynki finansowe charakteryzują się wysokim stopniem złożoności i dużą nieprzewidywalnością, co sprawia, że prognozowanie zmienności cen aktywów stanowi istotne wyzwanie analityczne. Szczególnie interesującym i wrażliwym na czynniki makroekonomiczne segmentem rynku jest sektor bankowy, którego kondycja finansowa często odzwierciedla ogólną sytuację gospodarczą. Inspiracją do podjęcia tematu była niestabilność finansowa obserwowana w sektorze bankowym na przestrzeni ostatniej dekady, obejmująca m.in. skutki pandemii COVID-19, napięcia geopolityczne oraz zmienność inflacyjną. Dodatkową motywacją była chęć zbadania, w jaki sposób coraz powszechniej stosowane modele predykcyjne oparte na uczeniu maszynowym radzą sobie z analizą tak zróżnicowanych i dynamicznych zjawisk; ale również zestawienie tych modeli z podejściem ekonometrycznym, takim jak model GARCH i potencjalne wykorzystanie modeli z obu grup w ramach podejścia hybrydowego.

Przedmiotem niniejszej pracy jest analiza i porównanie skuteczności wybranych modeli prognostycznych w zakresie prognozowania zmienności dziennych logarytmicznych stóp zwrotu akcji spółki PKO Bank Polski oraz indeksu sektorowego WIG-Banki. Celem pracy jest ocena jakości predykcji zmienności uzyskanych z modeli: ekonometrycznego modelu GARCH(1,1), rekurencyjnej sieci neuronowej LSTM, gradientowego modelu XGBoost oraz modelu hybrydowego GARCH-GRU, a także identyfikacja warunków, w których poszczególne podejścia okazują się najskuteczniejsze.

W pracy wykorzystano dane dzienne obejmujące notowania indeksu WIG-Banki i spółki PKO Bank Polski w latach 2013–2023. Dane te zostały poddane gruntownemu przygotowaniu oraz ustrukturyzowane z uwzględnieniem pięciu wyodrębnionych okresów rynkowych, odpowiadających kluczowym wydarzeniom makroekonomicznym i regulacyjnym. Wykorzystane źródła obejmują literaturę naukową z zakresu ekonometrii finansowej, uczenia maszynowego oraz publikacje branżowe dotyczące funkcjonowania sektora bankowego.

Metodyka badawcza obejmuje implementację i porównanie modeli prognostycznych za pomocą języka Python i odpowiednich bibliotek analitycznych. Modele były oceniane pod kątem trzech miar jakości: pierwiastka średniego błędu kwadratowego *RMSE*, średniego procentowego błędu bezwzględnego *MAPE* oraz współczynnika determinacji R^2 . Dodatkowo, uwzględniono aspekt długości okna agregacji zmienności: 5- dniowego,

10- dniowego oraz 20-dniowego, co pozwoliło na ocenę skuteczności prognoz w różnych horyzontach czasowych.

W rozdziale pierwszym przedstawiono przegląd literatury dotyczącej zmienności rynkowej oraz wykorzystywanych modeli prognostycznych. Rozdział drugi zawiera charakterystykę danych, opis segmentacji czasowej oraz konstrukcję zmiennych wykorzystywanych w badaniu. W rozdziale trzecim omówiono teoretyczne podstawy wybranych modeli i metryk ewaluacyjnych. Część czwarta dokumentuje proces implementacji poszczególnych modeli. Ostatni, piąty rozdział stanowi analizę porównawczą uzyskanych wyników oraz sformułowanie wniosków końcowych i rekomendacji.

1. Przegląd literatury

Definicja i znaczenie zmienności

W ostatnich latach modelowanie i prognozowanie zmienności zyskały dużą popularność, głównie ze względu na ich istotną rolę na rynkach finansowych. Wycena wielu instrumentów finansowych opiera się na estymacjach zmienności, traktując ją jako podstawowy miernik ryzyka.¹

W literaturze finansowej zmienność definiuje się jako miarę rozproszenia stóp zwrotu wokół ich średniej wartości. Autor książki *A Practical Guide to Forecasting Financial Market Volatility* zwraca uwagę, że zmienność powinna być rozumiana jako rozkład wszystkich możliwych wyników zmiennej losowej, przy czym w kontekście rynków finansowych najczęściej dotyczy to rozkładu zwrotów z aktywów. W kontekście analizy finansowej zmienność najczęściej szacuje się za pomocą odchylenia standardowego, obliczanego na podstawie próby. Miara ta cieszy się popularnością nie tylko ze względu na swoją interpretowalność, ale również ze względu na praktyczne właściwości obliczeniowe. W odróżnieniu od wariancji, która również bywa wykorzystywana jako wskaźnik zmienności, odchylenie standardowe charakteryzuje się większą stabilnością numeryczną i jest wyrażone w tych samych jednostkach co analizowany zwrot - na przykład w procentach lub walucie.²

Metody modelowania zmienności w literaturze

W książce *A Practical Guide to Forecasting Financial Market Volatility*, Poon szczegółowo omawia rozwój modeli heteroskedastyczności warunkowej, które stanowią jeden z fundamentów klasycznego modelowania zmienności. Autor przytacza model ARCH, zaproponowany przez Engle'a w 1982 roku, w którym warunkowa wariancja zależy wyłącznie od przeszłych kwadratów błędów prognozy. Choć podejście to pozwala uchwycić istotne właściwości danych finansowych, to jego praktyczne zastosowanie wymaga często estymacji dużej liczby parametrów.³

¹ L. Xiao, A. Aydemir, *Volatility modelling and forecasting in finance*, (w:) *Forecasting Volatility in the Financial Markets*, red. S. Satchell, J. Knight, Butterworth-Heinemann, Oxford 2007, s. 1.

² S. H. Poon, *A Practical Guide to Forecasting Financial Market Volatility*, Wiley, Chichester 2005, s. 1.

³ *Ib.*, s. 37-39.

W odpowiedzi na te ograniczenia Bollerslev zaproponował model GARCH (Generalized ARCH), który wprowadza dodatkową zależność od opóźnionych wartości samej wariancji. Dzięki temu możliwe jest zredukowanie złożoności przy zachowaniu zdolności modelu do odwzorowywania autoregresyjnego charakteru zmienności w czasie.⁴ Najczęściej stosowaną strukturą jest jednak model GARCH(1,1). Jak zaznacza Poon, model ten dobrze odzwierciedla dynamiczne właściwości zmienności rynkowej i znajduje szerokie zastosowanie w badaniach empirycznych.

Przechodząc do bardziej nowoczesnych podejść modelowania zmienności, należy przytoczyć jeden z najbardziej spopularyzowanych modeli – LSTM, czyli „Long Short-Term Memory”. Powszechnie rozpoznawalny model sieci neuronowych został zaproponowany przez S. Hochreiter’a i J. Schmidhuber’a w 1997 roku⁵. Autorzy publikując swój artykuł rozwiązali problem zanikającego gradientu, który wcześniej ograniczał naukę długoterminowych zależności w rekurencyjnych sieciach neuronowych (RNN). W odróżnieniu od wcześniej omawianego modelu GARCH, LSTM radzi sobie z niestacjonarnością danych, kiedy klasyczny GARCH zakłada ich stacjonarność.

Kolejnym istotnym przykładem algorytmu szeroko stosowanego w modelowaniu zmienności jest XGBoost (Extreme Gradient Boosting). Opracowany przez T. Chen’a w 2014 algorytm wykorzystujący metodę gradient boosting w krótkim czasie zyskał na popularności między innymi dzięki użyciu technik równoległego uczenia się oraz nieliniowemu podejściu do modelowania zmiennych⁶ przez co znakomicie radzi sobie w warunkach, w których inne, tradycyjne modele nie byłyby wystarczające.

⁴ S. H. Poon, *A Practical Guide to Forecasting Financial Market Volatility*, Wiley, Chichester 2005, s. 37-40.

⁵ S. Hochreiter, J. Schmidhuber, *Long Short-Term Memory*, „Neural Computation” 1997, t.9, nr 8., s. 1-9.

⁶ T. Chen, C. Guestrin *XGBoost: A Scalable Tree Boosting System*, (w:) „Proceedings of the 22nd AVM SIGDD International Conference on Knowledge Discovery and Data Mining” 2016, s. 1-13.

Przegląd zastosowań empirycznych

Jednym z przykładów w literaturze, który kompleksowo analizuje różne warianty modeli GARCH w kontekście precyzji w prognozowaniu zmienności, jest artykuł M. Sahiner'a – *Forecasting volatility in Asian financial markets: evidence from recursive and rolling window methods* z 2022 roku. Autor przeprowadził szczegółową analizę giełd z kontynentu azjatyckiego w różnorodnych ramach czasowych, porównując przy tym kilka odmian modeli typu GARCH. W pracy zaobserwowano pewną prawidłowość – modele niesymetryczne, w szczególności EGARCH, wykazują lepszą skuteczność w prognozowaniu zmienności na danych dziennych i tygodniowych, podczas gdy modele symetryczne sprawdzają się lepiej w przypadku danych miesięcznych. Sahiner domniema, że „może to być spowodowane zmniejszającą się dynamiką asymetrycznej zmienności w niższych częstotliwościach”⁷. Co więcej wybór metody : przesuwane okno (rolling window) lub metoda rekurencyjna (recursive method) oraz wybór statystyki błędu będą miały kluczowy wpływ na ocenę jakości modeli.⁸ Z perspektywy niniejszej pracy badanie Sahiner'a ma istotne znaczenie, ponieważ zarówno większość rynków azjatyckich, jaki i Giełda Papierów Wartościowych w Warszawie są rynkami wschodzącymi. Tym samym charakterystyka zmienności występująca na wschodzących rynkach azjatyckich może również być obserwowana na GPW w Warszawie, a przedstawione powyżej stwierdzenia autora artykułu mogą stanowić cenny punkt odniesienia.

Istotnym badaniem odnoszącym się do zastosowania modeli GARCH na rynkach wschodzących jest analiza zmienności przeprowadzona przez autorów artykułu *Comparison of linear and non-linear GARCH models for forecasting volatility of select emerging countries*. Praca obejmowała pięć rynków rozwijających się i uwzględniała wpływ globalnego kryzysu finansowego poprzez podział danych na dwa okresy: przedkryzysowy (2000–2008) i pokryzysowy (2009–2019). Wykorzystując klasyczny model GARCH(1,1) oraz jego asymetryczne rozszerzenia – EGARCH i TGARCH – autorzy wykazali, że zmienność rynków finansowych w krajach rozwijających się może być efektywnie modelowana zarówno przy pomocy podejść liniowych, jak i nieliniowych.⁹ Co ciekawe, w przeciwieństwie do wyników Sahiner'a z 2022 roku,

⁷ M. Sahiner, *Forecasting volatility in Asian financial markets: Evidence from recursive and rolling window methods*, „Journal of Economics, Finance and Accounting Studies” 2022, t. 2, nr 157, s. 69.

⁸ *Ib.*, s. 33-69.

⁹ S. Sharma, V. Aggrwal, *Comparison of linear and non-linear GARCH models for forecasting volatility of select emerging countries*, „Journal of Advances in Management Research” 2020, s. 14.

omawianych we wcześniejszej sekcji niniejszej pracy , to właśnie model GARCH(1,1) uzyskał najlepsze dopasowanie w analizowanych okresach dla większości rynków.

Chociaż tradycyjne modele GARCH oraz ich asymetryczne odmiany, takie jak EGARCH czy TGARCH, skutecznie sprawdzają się w analizie zmienności na rynkach finansowych, to postęp w dziedzinie głębokiego uczenia stworzył nowe perspektywy ich rozwoju. W związku z tym badacze zaczęli łączyć metody ekonometryczne z sieciami neuronowymi, prowadząc do powstania tzw. modeli hybrydowych. Zatem Wei, Yang i Cui w 2022 roku w artykule *Integrated GARCH-GRU in Financial Volatility Forecasting* zaproponowali hybrydowy model GARCH-GRU, łączący komponent GARCH(1,1) z architekturą sieci GRU (Gated Recurrent Unit). Model ten pozwala jednocześnie uchwycić stylizowane cechy zmienności, takie jak klastrowanie i trwałość, oraz skomplikowane nieliniowe zależności czasowe. W badaniach na indeksach amerykańskich GARCH-GRU uzyskał niższe błędy prognoz niż porównywane modele, a także wykazał lepszą skuteczność w prognozowaniu Value-at-Risk (VaR). Co istotne, autorzy podkreślają nie tylko wyższą precyzję, ale też większą efektywność obliczeniową względem modeli LSTM.¹⁰

Oprócz rozwiązań hybrydowych i klasycznych w literaturze dużą popularnością cieszą się typowe architektury uczenia maszynowego, takie jak LSTM, czy XGBoost. Przykładem takiego podejścia jest badanie Liu, Juang, Lin; w którym skupiono się na prognozowaniu zmienności ryzyka specyficznego dla poszczególnych akcji. Autorzy, wykorzystując możliwości rekurencyjnych sieci neuronowych LSTM, zaproponowali innowacyjne podejście polegające na jednoczesnym uwzględnieniu specyficznych czynników ryzyka wielu akcji. Zastosowanie tego rozwiązania pozwoliło na uzyskanie lepszych wyników predykcyjnych w zestawieniu z tradycyjnym modelem GARCH.¹¹

Podkreśleniem rosnącej roli machine learningu w analizie zmienności jest badanie Ding, Cui i Zhang z 2022 roku, w którym autorzy zastosowali algorytm XGBoost do modelowania zmienności na rynkach futures ropy naftowej oraz energii elektrycznej. W pracy wykazano, że modele oparte na XGBoost przewyższają tradycyjne podejścia, takie jak GARCH, HAR (Heterogeneous Autoregressive Model) oraz modele sieci neuronowych, zarówno pod względem dokładności prognoz w próbie, jak i poza nią.

¹⁰ J. Wei, S. Yang, Z. Cui, *Integrated GARCH-GRU in Financial Volatility Forecasting*, Stevens Institute of Technology 2022, s. 18-21.

¹¹ R. Liu, Y. Jiang, J. Lin, *Forecasting the Volatility of Specific Risk for Stocks with LSTM*, „Proceedings of the International Conference on Identification, Information and Knowledge in the Internet of Things” 2021, nr 202, s. 111-114.

Szczególnie interesującym aspektem tej analizy było uwzględnienie efektu nierównowagi zleceń jako czynnika wpływającego na zmienność – autorzy argumentują, że tego typu informacje mogą odzwierciedlać ukryte siły podaży i popytu, niosąc istotne sygnały handlowe. Wyniki te nie tylko potwierdzają skuteczność podejść opartych na big data w kontekście zmienności, lecz także wskazują na praktyczne zastosowania modeli XGBoost w planowaniu operacyjnym i strategiach zarządzania ryzykiem na rynkach surowcowych.¹²

¹² S. Ding, T. Cui, Y. Zhang, *Futures volatility forecasting based on big data analytics with incorporating an order imbalance effect*, „International Review of Financial Analysis” 2022, nr 83, s. 8-11.

2. Zmienność cen akcji w sektorze bankowym – dane i struktura analizy

2.1. Znaczenie zmienności w ocenie kondycji sektora bankowego

Zmienność jako wskaźnik statystyczny jest narzędziem, które pozwala zrozumieć rynek finansowy i przy tym utworzyć stabilną strategię inwestycyjną. Dla każdego typu rynku i jego odbiorców czynniki kształtujące zmienność mają inną wagę w kontekście siły działania na ruchy cen. Ogólnymi czynnikami wpływającymi na zmienność na rynkach kapitałowych są między innymi: wydarzenia polityczne, wydarzenia makroekonomiczne, wydarzenia w gospodarce globalnej, ale także psychologia rynku lub czynniki sezonowe.¹³

W kontekście sektora bankowego bardzo duże znaczenie ma polityka monetarna państwa. Bank Centralny podejmując się prowadzenia restrykcyjnej polityki monetarnej, na przykład w celu kontroli inflacji, powszechnie stosuje podwyższenie stóp procentowych. Taka interwencja znacząco wpływa na rentowność banków. Z kolei ekspansywna polityka monetarna prowadzi do zwiększenia popytu kredytowego i obniżenia kosztów z tym związanych. Poprzez takie zabiegi, rynek finansowy często gwałtownie reaguje na zmiany, co prowadzi do istotnego zwiększenia amplitudy zmienności.

Wpływ na wahania w sektorze bankowym ma również cykl koniunkturalny gospodarki. W zależności w jakiej fazie rozwoju znajduje się gospodarka, tak kształtuje się dynamika popytu na pieniądz kredytowy. Na początku fazy wzrostowej tempo zmian może cechować się podwyższoną intensywnością i spadać wraz ze schyłkiem pozytywnej fazy rozwoju. Wysoki popyt na dobra inwestycyjne i konsumpcyjne na początku fazy ożywienia cyklu koniunkturalnego, który jest spowodowany wzrostem takich wielkości gospodarczych jak produkcja, inwestycje lub zatrudnienie; sprzyja większemu zainteresowaniu finansowaniem poprzez kredyt. Natomiast w fazie rozkwitu następuje dalszy rozwój gospodarczy, jednak tempo tego wzrostu ulega spowolnieniu. Spadek ten następnie utrzymuje się przez kolejne fazy cyklu koniunkturalnego, aż do ponownego nadejścia fazy ożywienia.¹⁴

¹³ ZasadyForex, *Co wpływa na zmienność na rynkach kapitałowych?*, ZasadyForex.pl, <https://zasadyforex.pl/co-wplywa-na-zmienosc-na-rynkach-kapitalowych/>, dostęp: 14.04.2025,

¹⁴ R. Barczyk, *Morfologia cykli koniunkturalnych i cykli bankowych w gospodarce polskiej w latach 2000-2017*, „Prace naukowe Uniwersytetu Ekonomicznego we Wrocławiu” 2018, nr 509.

Zmiany regulacyjne w sektorze bankowym odgrywają istotną rolę w kształtowaniu poziomu zmienności i niepewności finansowej. Czas ich wprowadzania wiąże się z podwyższoną niepewnością, co samo w sobie może przełożyć się na krótkoterminową destabilizację systemu. Jak zauważono, „okres takich zmian sam w sobie nie sprzyja jego (polskiego sektora bankowego) stabilności finansowej¹⁵”, a banki „znajdują się w sytuacji wysokiej niepewności swoich oczekiwań w zakresie zmian ich dyscypliny regulacyjnej.¹⁶” Ryzyko to ma jednak charakter krótkoterminowy i zależy od skali oraz rodzaju wdrażanych przepisów. W dłuższej perspektywie regulacje te mają na celu wzmocnienie odporności sektora bankowego poprzez zwiększenie jego stabilności. Na przykładzie regulacji Bazylea III stwierdzono, że kluczowym elementem procesu stabilizacji sektora jest „zwiększenie ilości kapitałów własnych w strukturze finansowania”¹⁷, które „stanowi najprostsze i najbardziej efektywne rozwiązanie pozwalające podnieść bezpieczeństwo instytucji oraz całego systemu finansowego”.¹⁸

2.2. Dobór próby badawczej

W niniejszym rozdziale nastąpi krótkie przedstawienie wybranej próby badawczej składającej się z indeksu WIG-Banki oraz spółki PKO Bank Polski, wraz z uzasadnieniem wyboru tych instrumentów jako reprezentatywnych dla polskiego sektora bankowego.

2.2.1. Indeks WIG-Banki

Indeks WIG-Banki jest indeksem sektorowym notowanym na Giełdzie Papierów Wartościowych w Warszawie. Składa się on z największych i najbardziej płynnych spółek akcyjnych, które wchodzi w skład sektora bankowego, a jednocześnie są notowane w indeksie WIG. Jest on indeksem dochodowym, czyli przy obliczaniu jego wartości bierze się pod uwagę ceny akcji, dochody z dywidend i dochody z praw poboru. Zmiana listy uczestników indeksu i okresowa zmiany portfela przeprowadzone są co kwartał, jest to tzw. rewizja kwartalna.¹⁹

¹⁵ I. Pryka, *Nowe regulacje bankowe a stabilność finansowa polskiego sektora bankowego*, „Studia Ekonomiczne” 2014, nr 186, s.196-206.

¹⁶ Ib.

¹⁷ M. Borsuk, *Wpływ Bazylei III na pozycję kapitałową polskich banków*, (w:) „Studia z Zakresu Prawa, Administracji i Zarządzania” 2015, t.8, s. 114-128,

¹⁸ Ib.

¹⁹ GPW karta indeksu <https://gpwbenchmark.pl/karta-indeksu?isin=PL9999999904>, [dostęp: 05.05.2025].

W poniższej tabeli przedstawiono strukturę według udziałów poszczególnych banków indeksu WIG-Banki.

Tabela 1 Skład indeksu WIG-Banki

Wybór indeksu WIG-Banki pozwala na uchwycenie zmienności w całym sektorze bankowym w Polsce, ale także pozwala na zobrazowanie ogólnej sytuacji sektora, gdyż

PEŁNA NAZWA	SKRÓT	PROCENTOWY UDZIAŁ W PORTFELU
POWSZECHNA KASA OSZCZĘDNOŚCI BANK POLSKI SPÓŁKA AKCYJNA	PKOBP	34,021%
BANK POLSKA KASA OPIEKI SPÓŁKA AKCYJNA	PEKAO	21,451%
SANTANDER BANK POLSKA SPÓŁKA AKCYJNA	SANPL	13,226%
MBANK SPÓŁKA AKCYJNA	MBANK	7,170%
ING BANK ŚLĄSKI SPÓŁKA AKCYJNA	INGBSK	6,768%
ALIOR BANK SPÓŁKA AKCYJNA	ALIOR	6,337%
BANK MILLENNIUM SPÓŁKA AKCYJNA	MILLENNIUM	5,969%
BANK HANDLOWY W WARSZAWIE SPÓŁKA AKCYJNA	HANDLOWY	2,602%
BNP PARIBAS BANK POLSKA SPÓŁKA AKCYJNA	BNPPPL	1,917%
UNICREDIT S.P.A.	UNICREDIT	0,299%
BANK OCHRONY ŚRODOWISKA SPÓŁKA AKCYJNA	BOS	0,183%
GETIN HOLDING SPÓŁKA AKCYJNA	GETIN	0,039%
BANCO SANTANDER S.A.	SANTANDER	0,020%

Źródło: Opracowanie własne na podstawie danych z GPW Benchmark - Karta indeksu

jest on wrażliwy na wydarzenia systemowe oraz decyzje z zakresu polityki monetarnej.

2.2.2. Spółka PKO Bank Polski

Powszechna Kasa Oszczędności Bank Polski to największy bank uniwersalny w Polsce. Jest również jedną z największych spółek akcyjnych notowanych na GPW w Warszawie pod względem kapitalizacji jak i udziału w indeksach giełdowych. W 2025

roku jego udział procentowy w portfelu indeksu WIG wynosi 10,057%²⁰, natomiast w opisywanym powyżej subindeksie WIG-Banki - 34,021%²¹, tak wysoki udział sprawia że zmienność kursu PKO ma znaczący wpływ na zachowanie i procesy w sektorze finansowym GPW. Spółka charakteryzuje się wysoką płynnością giełdową, a jej notowania są wrażliwe zarówno na ogólne zmiany sektorowe jak i wewnętrzne dla samej spółki.

2.2.3. Uzasadnienie wyboru zestawu danych

Zastosowanie dwóch poziomów agregacji danych tzn. indeksu oraz spółki akcyjnej pozwala na przeprowadzenie analizy porównawczej prognozowania zmienności. Dane o charakterze zbiorczym mogą cechować się odmienną strukturą zmienności niż dane jednostkowe, więc porównanie modeli może dostarczyć wartościowych informacji na temat ich skuteczności dla różnego typu danych .

2.3. Segmentacja czasowa danych według kluczowych wydarzeń rynkowych

Zbiór danych wykorzystany w niniejszej pracy zawiera ceny zamknięcia indeksu WIG-Banki i spółki PKO Bank Polski, a także obejmuje około 10 letni okres czasowy od 01.09.2013 do 31.12.2023. Został on podzielony na 5 podokresów w celu zbadania skuteczności wybranych modeli w różnych fazach rynkowych. Każdy z analizowanych okresów charakteryzuje się unikalnym zestawem cech i zdarzeń, które zostały wyselekcjonowane ze względu na ich wpływ na sektor finansowy, stanowiący źródło zestawu danych. Wszystkie analizowane okresy obejmują przedziały od 500 do 550 dni, co pozwala zachować spójność i porównywalność wyników pomiędzy poszczególnymi modelami. Poniżej przedstawiono charakterystykę każdego z tych okresów oraz czynniki, które mogły mieć wpływ na zmienność w danym okresie.

²⁰ GPW karta indeksu [GPW Benchmark - Karta indeksu](#), [dostęp: 05.05.2025].

²¹ GPW karta indeksu [GPW Benchmark - Karta indeksu](#), [dostęp: 05.05.2025].

OKRES I

01.09.2013r.-31.10.2015r.

Okres ten przede wszystkim wiąże się z początkiem wdrożeń zestawu regulacji europejskich Bazylea III do polskich banków. Założeniem Bazylea III było przede wszystkim wzmocnienie stabilności sektora bankowego na kryzysy finansowe, jako reakcja na kryzys z 2008 roku. Jednym z elementów, który został wprowadzony w tych latach było wzmocnienie kapitału podstawowego (CET1) i utrzymanie go na poziomie 4,5% aktywów ważonych ryzykiem.²² Dodatkowo na arenie międzynarodowej pojawił się problem wojny w Donbasie i aneksji Krymu przez Rosję co wzbudziło wzrost napięć geopolitycznych i mogło mieć możliwy wpływ na sektor finansowy poprzez przykładowo niepokoje inwestycyjne.

OKRES II

01.11.2015r.-31.12.2017r.

Decyzja Szwajcarskiego Banku Centralnego o uwolnieniu kursu CHF była przyczyną gwałtownego wzrostu rat kredytów frankowych w 2015 roku. Sektor bankowy stanął pod dużą presją społeczną w kwestii stworzenia możliwości przewalutowania kredytów, a także zmagał się z licznymi pozwami sądowymi. W 2015 roku nastąpiła również zmiana władzy, która zapowiadała przewalutowanie kredytów na złotówki po kursie z dnia zaciągnięcia, co dla sektora bankowego wiązałoby się z kosztem sięgającym kilkudziesięciu miliardów. W okresie tym również został wprowadzony program 500+, który bezpośrednio miał wpływ na wzrost konsumpcji oraz zwiększenie się popytu na kredyty. Działaniem, które również mogło mieć wpływ na sektor finansowy było wprowadzenie podatku bankowego w 2016 roku.

²² A. Gemzik-Salwach, *Skutki regulacji Bazylei III dla sektora bankowego i gospodarki*, „Annales Universitatis Mariae Curie-Skłodowska Lublin-Polonia” 2012, t. 46, nr 4, s. 201.

OKRES III

01.01.2018r.-31.12.2019r.

Okres ten związany jest ze znacznym spopularyzowaniem mobilnej bankowości i cyfryzacją procesów. Zaliczony jest on raczej do okresów umiarkowanie stabilnych ze wzrostem PKB , niskim poziomem bezrobocia, ale także wzrostem popularności kredytów konsumpcyjnych.

OKRES IV

01.01.2020r.-31.12.2021r.

Okres znacznego niepokoju w sektorze bankowym. Wybuch pandemii COVID-19 spowodował spadek PKB o ponad 2%. Narodowy Bank Polski obniżył główną stopę referencyjną do rekordowo niskiego poziomu 0,1%, co skutkowało znacznym obniżeniem rentowności sektora bankowego. Dodatkowo banki uczestniczyły jako w dystrybucji pomocy finansowej w ramach „Tarczy Finansowej” Polskiego Funduszu Rozwoju, co nałożyło na nie dodatkowe obowiązki operacyjno-prawne.

OKRES V

01.01.2022r.-31.12.2023r.

Jest to kolejny okres, którego głównym tematem był wybuch wojny na Ukrainie. Konsekwencją tego zdarzenia dla sektora bankowości była potrzeba uwzględnienia dodatkowego ryzyka w modelach oceny kredytowej, ponieważ wiele inwestorów zagranicznych wycofała się albo została odstraszone uznając Polskę za region mniej stabilny. Następnie najwyższa inflacja od ponad 20 lat sprawiła spadek popytu na kredyty, a podwyżki stóp procentowych w teorii sprawiły, że banki miały większe przychody odsetkowe, ale jednocześnie mocno wzrosły koszty ryzyka , ponieważ wiele klientów miało problemy ze spłatą rat.

2.4. Proces przygotowania danych i konstrukcja zmiennych

Skuteczność modeli prognostycznych w dużej mierze zależy od jakości danych wejściowych oraz sposobu ich przekształcenia. W niniejszym podrozdziale przedstawiono etapy przygotowania danych do analizy, w tym oczyszczenie zbioru i transformacje zmiennych, które następnie zostały wykorzystane w procesie modelowania zmienności.

2.4.1. Oczyszczanie danych i przygotowanie do analizy

Zestaw danych wykorzystywany w niniejszej pracy zawiera dwie podstawowe kolumny: „Data” oraz „Zamknięcie”. Pierwsza kolumna zawiera daty sesji giełdowych uporządkowane w kolejności chronologicznej, natomiast weekendy zostały pominięte. Druga kolumna zawiera ceny zamknięcia notowań giełdowych odpowiadających dniu z kolumny pierwszej. Dane te zostały pobrane ze strony stooq.pl.

Problem braków danych został rozwiązany za pomocą metody forward-fill. Polega ona na uzupełnieniu brakującej wartości w szeregu czasowym poprzez przypisanie do tego braku danej ostatniej dostępnej wartości.²³ Technika ta jest powszechnie stosowana przy przetwarzaniu danych dziennych, gdzie brakujące wartości często wynikają z powodu dni wolnych od sesji giełdowych. Jest to istotny punkt przygotowania danych, ponieważ w ten sposób zostanie zachowana ciągłość szeregu czasowego.

2.4.2. Konstrukcje zmiennych

W niniejszym podrozdziale przedstawiono sposób konstrukcji zmiennych wykorzystywanych w modelowaniu zmienności w pracy. Opisano logarytmiczne stopy zwrotu oraz zmienność, a następnie omówiono jak przedstawione zmienne wykorzystywane są w różnych typach modeli jako zmienne wejściowe i wyjściowe.

Używanie stóp zwrotu w szeregach danych finansowych, a nie bezwzględnych poziomów cen, stało się standardową praktyką ze względu na możliwość porównania ich w czasie oraz ich relatywnie większe możliwości odzwierciedlenia zmiany wartości aktywów. Wśród dostępnych wariantów stóp zwrotu najbardziej popularną jest logarytmiczna stopa zwrotu, znana również jako stopa zwrotu przy kapitalizacji ciągłej. Posiada ona lepszą symetrię rozkładu niż prosta stopa zwrotu, tzn. rozkład bliższy rozkładowi normalnemu. Logarytmiczna stopa zwrotu jest również addytywna w czasie, co

²³ Pandas Documentation <https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.fillna.html>

znacząco ułatwia agregację; ale także wyróżnia się większą stacjonarnością - co z kolei jest kluczowym elementem do wykorzystania w modelach uczenia maszynowego.²⁴ Dzienna logarytmiczna stopa zwrotu definiowana jest poniżej.

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) \quad (1)$$

Gdzie P_t oznacza cenę zamknięcia instrumentu finansowego w dniu t .

Zmienność jak wcześniej przedstawiono jest kluczową miarą ryzyka na rynkach finansowych, opisującą w określonym przedziale czasowym zakres wahań aktywów. W literaturze finansowej jako definicje matematyczną najczęściej przyjmuje się odchylenie standardowe stóp zwrotu. W niniejszej analizie jako podstawę obliczeń przyjęto logarytmiczne stopy zwrotu, więc na ich podstawie liczona jest zmienność, która jest głównym celem tego badania²⁵. Tak pojmowana zmienność, nazywana również zmiennością realizowaną, definiowana poniżej.

$$\sigma_t = \sqrt{\frac{1}{n-1} \sum_{i=0}^{n-1} (r_{t-i} - \bar{r})^2} \quad (2)$$

Gdzie:

σ_t – oszacowana zmienność w dniu t ,

n – liczba dni (długość okna ruchomego),

r_{t-i} – logarytmiczna stopa zwrotu w dniu $t-i$,

$\bar{r}$ – średnia arytmetyczna z logarytmicznych stóp zwrotu z ostatnich n dni.

W niniejszej pracy zastosowano trzy różne długości okna ruchomego:

- okno 5 – dniowe – odpowiadające zmienności tygodniowej,
- okno 10 – dniowe – odpowiadające zmienności dwutygodniowej,
- okno 20 – dniowe – odpowiadające zmienności miesięcznej.

²⁴ R. S. Tsay, *Analysis of Financial Time Series*, Wiley, Hoboken 2010, s. 4-21.


²⁵ S. J. Taylor, *Asset Price Dynamics, Volatility, and Prediction*, Princeton University Press, Princeton 2011, s.189-191.

Okna o mniejszej długości pozwalają na szybsze wychwytywanie reakcji rynku na nowe wydarzenia, aczkolwiek cechują się większą podatnością na wahania i szумы. Z kolei dłuższe okna, choć oferują większą stabilność prognoz zmienności, mogą opóźniać wykrywanie nagłych zmian na rynku.

2.5. Charakterystyka zmienności w ujęciu wstępnym

W niniejszym podrozdziale przedstawiona została wstępna analiza zmienności cen w pięciu badanych okresach, której celem było rozpoznanie ogólnego charakteru zmienności, fluktuacji w ujęciu czasowym oraz zależności od kondycji rynku.

W celu zilustrowania dynamiki zmienności w badanych okresach poniżej przedstawiony został zbiór wykresów przedstawiającą tygodniową, dwutygodniową oraz miesięczną zmienność realizowaną dla spółki PKO Bank Polski oraz indeksu WIG-Banki.




Rysunek 1 Zmienność realizowana dla indeksu WIG-Banki obliczana w ruchomych oknach 5-, 10- i 20-dniowych w pięciu wyodrębnionych okresach rynkowych.

Źródło: Opracowanie własne

Z przedstawionego wykresu wywnioskowano, że wraz ze wzrostem długości okna estymacyjnego, wykresy zmienności ulegają wygładzeniu. Zmienność tygodniowa charakteryzuje się silnymi krótkoterminowymi wahaniami, co zmniejsza się wraz z wydłużeniem okresu, na którym liczona jest zmienna. Finalnie dla najdłuższego okresu branego pod uwagę, czyli miesięcznego, można lepiej dostrzec ogólny trend w danych i faktyczne epizody o wysokiej zmienności. Wykresy pozwalają zaobserwować, że najbardziej wyraźne fluktuacje pojawiają się na początku okresu IV oraz V. Okres IV jest powiązany z rozpoczęciem pandemii COVID-19, natomiast okres V z wybuchem wojny na Ukrainie. Natomiast inny profil zmienności zaobserwowano dla pozostałych okresów, w których przebieg tego czynnika zdaje się bardziej uporządkowany, z największymi pikami w granicach 0,03; czyli około dwukrotnie mniej niż w najwyższej wartości w okresie IV i V.

Dla pełniejszego obrazu przeanalizowano również zmienność spółki PKO Bank Polski, której przebieg zmienności może różnić się od zagregowanego indeksu, ze względu na indywidualny charakter spółki.

Zmienność - PKO



Rysunek 2 Zmienność realizowana dla PKO Bank Polski obliczana w ruchomych oknach 5-, 10- i 20-dniowych w pięciu wyodrębnionych okresach rynkowych.

Źródło: Opracowanie własne

Wnioski dotyczące wpływu długości okna estymacyjnego na kształt zmienności oraz ogólne zależności obserwowane w poszczególnych okresach rynkowych pozostają zbliżone zarówno dla spółki PKO Bank Polski, jak i dla indeksu WIG-Banki. Różnice dotyczą głównie intensywności reakcji – w przypadku PKO zmienność wykazuje nieco wyraźniejsze skoki, co może odzwierciedlać większą ekspozycję pojedynczej spółki na zmiany informacyjne oraz brak efektu wygładzającego, charakterystycznego dla indeksu zbiorczego.

W celu uzupełniania przedstawionej powyżej analizy graficznej zestawiono podstawowe statystyki opisowe zmienności realizowanej dla spółki PKO Bank Polski i indeksu WIG-Banki.

Tabela 2 Statystyki opisowe zmienności realizowanej (PKO Bank Polski i WIG-Banki) w podziale na okresy rynkowe i długości okien

Okres	Okno	Zbiór danych	Średnia zmienność	Min	Max	Współczynnik zmienności
OKRES I	5	PKO	0,014	0,0026	0,0455	0,478
		WIG-Banki	0,011	0,0017	0,0339	0,477
	10	PKO	0,014	0,0054	0,0346	0,359
		WIG-Banki	0,012	0,0039	0,0263	0,357
	20	PKO	0,015	0,0081	0,0297	0,289
		WIG-Banki	0,012	0,0061	0,0232	0,283
OKRES II	5	PKO	0,017	0,0024	0,0489	0,465
		WIG-Banki	0,012	0,0017	0,0359	0,490
	10	PKO	0,017	0,0053	0,0360	0,334
		WIG-Banki	0,013	0,0033	0,0279	0,360
	20	PKO	0,018	0,0080	0,0308	0,248
		WIG-Banki	0,013	0,0050	0,0246	0,291
OKRES III	5	PKO	0,015	0,0024	0,0385	0,416
		WIG-Banki	0,011	0,0014	0,0300	0,437
	10	PKO	0,016	0,0057	0,0292	0,290
		WIG-Banki	0,012	0,0035	0,0226	0,321
	20	PKO	0,016	0,0083	0,0246	0,215
		WIG-Banki	0,012	0,0051	0,0191	0,244
OKRES IV	5	PKO	0,021	0,0034	0,0697	0,536
		WIG-Banki	0,019	0,0017	0,0931	0,619
	10	PKO	0,022	0,0091	0,0661	0,442
		WIG-Banki	0,020	0,0048	0,0734	0,529
	20	PKO	0,023	0,0094	0,0559	0,377
		WIG-Banki	0,021	0,0072	0,0580	0,460
OKRES V	5	PKO	0,021	0,0020	0,1134	0,608
		WIG-Banki	0,019	0,0029	0,1058	0,593
	10	PKO	0,022	0,0044	0,0874	0,484
		WIG-Banki	0,020	0,0063	0,0812	0,475
	20	PKO	0,023	0,0111	0,0639	0,408
		WIG-Banki	0,021	0,0113	0,0595	0,405

Źródło: Opracowanie własne

Zestawione wartości w powyższej tabeli potwierdzają wcześniejsze obserwacje. Średni poziom zmienności jest zawsze wyższy dla pojedynczej spółki, a najwyższe maksymalne wartości wystąpiły w IV i V okresie. Współczynnik zmienności potwierdza, że PKO jest bardziej wrażliwe na krótkoterminowe wahania niż indeks WIG-Banki. Różnice najbardziej widoczne są w okresach szoków rynkowych oraz przy krótszych oknach estymacyjnych.

3. Teoretyczne podstawy modeli

W tym rozdziale prezentowany jest kompleksowy przegląd teoretycznych podstaw wykorzystanych w pracy modeli, poczynając od konstrukcji równoważnych formuł matematycznych opisujących dynamikę zmienności finansowej. Rozważane są zarówno klasyczne podejścia ekonometryczne, jak i zaawansowane metody uczenia maszynowego oraz ich hybrydy, ukazując ich wzajemne uzupełnianie oraz odpowiednie obszary zastosowań.

3.1. Model GARCH

Model uogólnionej autoregresyjnej heteroskedastyczności warunkowej (ang. Generalized Autoregressive Conditional Heteroskedasticity), znany jako GARCH, został wprowadzony w celu uchwycenia efektu klasteryzacji zmienności. Oznacza to, że zmienność obserwowana na rynkach finansowych cechuje się tendencją występowania po sobie okresów dużych wahań, tak samo jak w przypadku niskich wahań. Model ten uwzględnia zależność bieżącej zmienności od przeszłych szoków oraz wcześniejszych jej poziomów. Pozwala to na odwzorowanie zmian zmienności w czasie na podstawie wcześniejszych obserwacji.²⁶

GARCH estymuje zmienność warunkową za pomocą metody największej wiarygodności, a jego konstrukcja opiera się na założeniu dotyczącym procesu generowania stóp zwrotu, gdzie każda obserwacja r_t może być matematycznie opisana jak przedstawiono poniżej.²⁷

$$r_t = \mu + \varepsilon_t, \tag{3}$$

Gdzie:

- r_t – stopa zwrotu w okresie t ,
- ε_t – reszta losowa w okresie t ,
- $\varepsilon_t = \sqrt{h_t}z_t$, w którym $h_t = \sigma_t^2$, a $z_t \sim N(0, 1)$ ²⁸,
- z_t – biały szum,

²⁶ L. Xiao, A. Aydemir, *Volatility modelling and forecasting in finance*, (w:) „Forecasting volatility in the financial markets”, red. S. Satchell, J. Knight, Butterworth-Heinemann, Oxford 2007, s. 5-7.

²⁷ S. H. Poon, *A Practical Guide to Forecasting Financial Market Volatility*, Wiley, Chichester 2005, s. 37-39.

²⁸ Ib..

- h_t – warunkowa wariancja reszty ε_t w chwili t ,
- μ – średnia wartość stopy zwrotu.

Jak wcześniej wspomniano h_t jest warunkową zmiennością, która w modelu GARCH zależy od przeszłych wartości kwadratów reszt oraz przeszłych wartości wariancji, co pokazano poniżej.

$$h_t = \omega + \sum_{j=1}^q \alpha_j \varepsilon_{t-j}^2 + \sum_{i=1}^p \beta_i h_{t-i}, \quad (4)$$

Gdzie:

- p - liczba opóźnień wariancji ,
- q - liczba opóźnień reszt kwadratów,
- h_t – warunkowa wariancja w chwili t ,
- ω – dodatnia stała bazowa modelu,
- ε_{t-j}^2 – kwadrat zakłócenia reszty w chwili $t - j$,
- α_j – współczynnik mierzący wpływ wcześniejszych szoków na bieżącą zmienność,
- β_i – współczynnik opisujący wpływ wcześniejszych wartości wariancji na wartość h_t .²⁹

Natomiast w niniejszej pracy wykorzystano szczególny przypadek modelu GARCH, a mianowicie GARCH(1, 1); czyli o model wartościach p i q równych jeden. Oznacza to, że wariancja modelu zależy tylko od jednej wartości przeszłej reszty oraz jednej wartości przeszłej wariancji i wyrażona jest wzorem przedstawionym poniżej.³⁰

$$h_{t+1} = \omega + \alpha_1 \varepsilon_t^2 + \beta_1 h_t \quad (5)$$


²⁹ S. H. Poon, *A Practical Guide to Forecasting Financial Market Volatility*, Wiley, Chichester 2005, s. 37-39.

³⁰ Ib.

3.2. LSTM

W niniejszym podrozdziale został omówiony model LSTM, który jest wariantem rekurencyjnej sieci neuronowej (RNN) rozwiązujący problem zanikających gradientów poprzez wprowadzenie pętli auto-referencyjnej w komórce pamięci.³¹ Dzięki sterowanym przez bramki przepływowi informacji sieć może dynamicznie decydować, które dane utrzymać a które odrzucić. Takie działanie pozwala na zapamiętanie zależności rozciągających się na długie sekwencje, dzięki takiej cesze LSTM znalazło szereg zastosowań, w których kluczowe są relacje w odległym kontekście.³²

Poniżej przedstawiono rysunek obrazujący strukturę pojedynczej komórki LSTM, na bazie którego omówiono poszczególne składniki jej struktury.



Rysunek 3 Pojedyncza komórka sieci LSTM

Źródło: Y. Liu, J. Cheng, H. Zhang, H. Zou, N. Xiong, *Long Short-Term Memory Networks Based on Particle Filter for Object Tracking*, „IEEE Access” 2020, t.8

Taka oto komórka pamięci, zwana również blokiem pamięciowym składa się z głównych elementów; czyli bramek zapomnienia, wejścia i wyjścia oraz głównej warstwy.

Wszystkie procesy zachodzące w komórce LSTM zdefiniowano poniżej.

³¹ S. Hochreiter, J. Schmidhuber, *Long Short-Term Memory*, „Neural Computation” 1997, t.9, nr 8., s. 22-23.

³² I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, Springer, 2016, s. 410.

$$f_t = \sigma(W_{xf}^T x_{(t)} + W_{hf}^T h_{(t-1)} + b_f) \quad (6)$$

$$\tilde{c}_t = \tanh(W_{x\tilde{c}}^T x_{(t)} + W_{h\tilde{c}}^T h_{(t-1)} + b_{\tilde{c}}) \quad (7)$$

$$i_t = \sigma(W_{xi}^T x_{(t)} + W_{hi}^T h_{(t-1)} + b_i) \quad (8)$$

$$o_t = \sigma(W_{xo}^T x_{(t)} + W_{ho}^T h_{(t-1)} + b_o) \quad (9)$$

$$c_t = f_t \otimes c_{(t-1)} + i_t \otimes \tilde{c}_t \quad (10)$$


$$h_t = o_t \otimes \tanh(c_t) \quad (11)$$

Gdzie:

- $\tilde{c}_t$ – wartość wektora warstwy głównej w chwili t ;
- i_t – wartość wektora bramki wejściowej w chwili t ;
- o_t – wartość wektora bramki wyjściowej w chwili t ;
- f_t – wartość bramki zapomnienia w chwili t ;
- σ – funkcja sigmoidalna;
- $\tanh$ - funkcja tangens hiperboliczny;
- $W_{xo}^T, W_{xf}^T, W_{xi}^T, W_{x\tilde{c}}^T$ - macierze wag warstw dla ich połączenia z wektorem $x^{(t)}$;
- $W_{ho}^T, W_{hf}^T, W_{hi}^T, W_{h\tilde{c}}^T$ - macierze wag warstw dla ich połączenia z poprzednim stanem krótkotrwałym $h_{(t-1)}$;
- $x_{(t)}$ – wartość wektora wejściowego w chwili t ;
- $h_{(t-1)}$ – wartość wektora ukrytego w chwili $t-1$;
- $b_f, b_{\tilde{c}}, b_i, b_o$ – człon obciążenia warstwy;
- $\otimes$ - znak iloczynu.³³

³³ A. Geron, *Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow*, Helion, Gliwice 2020, s.504-505.

Pierwsza z wymienionych bramek, czyli bramka zapomnienia przybliżona została poniżej.




Rysunek 4 Bramka zapomnienia, część Rysunku 1.

Źródło: Y. Liu, J. Cheng, H. Zhang, H. Zou, N.

Xiong, Long Short-Term Memory Networks Based on Particle Filter for Object Tracking, „IEEE Access” 2020, t.8

Bramka zapomnienia decyduje o tym jakie informacje przechowywane w stanie komórki z poprzedniego kroku czasowego (c_{t-1} na Rys. 2.) powinny zostać zachowane. Działa ona w następujący sposób: na podstawie aktualnego wejścia (x_t na Rys. 2.) oraz poprzedniego stanu ukrytego (h_{t-1} na Rys. 2.) aktywacyjna funkcja sigmoidalna generuje wartości od 0 do 1, które następnie zostają kolejno wymnożone przez elementy zawierające się w wektorze stanu komórki. Wynikiem tego jest zestaw, w którym wartości bliższe 0 oznaczają usunięcie informacji, w przeciwieństwie do wartości bliższych 1, które oznaczają ich zachowanie.³⁴

Z kolei bramka wejściowa i warstwa główna są kolejnymi kluczowymi strukturami komórki LSTM i zostały przedstawione na poniższym rysunku.




Rysunek 5 Bramka wejścia oraz bramka główna, część Rysunku 1.

Źródło: Y. Liu, J. Cheng, H. Zhang, H. Zou, N. Xiong, Long Short-Term Memory Networks Based on Particle Filter for Object Tracking, „IEEE Access” 2020, t.8

³⁴ I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, Springer, 2016, s.410.

W głównej warstwie zachodzi aktualizacja stanu komórki poprzez wygenerowanie wartości wektora $\tilde{c}_t$ (Rys. 3.). Proces ten zachodzi poprzez analizę przez funkcje aktywacji tangens hiperboliczny aktualnych danych wejściowych oraz poprzedniego stanu komórki. W architekturze LSTM wynik tej analizy nie jest bezpośrednio przekazywany dalej, ale tylko wybrane informacje zostaną zapisane w stanie długotrwałym. Natomiast zadaniem bramki wejściowej jest określenie dokładnie które elementy zostaną ujęte w stanie długotrwałym, które wcześniej zostały wygenerowane i umieszczone w wektorze $\tilde{c}_t$.³⁵

Finalną bramką komórki LSTM jest bramka wyjściowa, która jest odpowiedzialna za wybranie komponentów, które mają być ujawnione jako wyjście w danym kroku czasowym. Poniżej przedstawiono rysunek opisujący ten proces.³⁶



Rysunek 6 Bramka wyjścia, część Rysunku 1.
Źródło: Y. Liu, J. Cheng, H. Zhang, H. Zou, N. Xiong, Long Short-Term Memory Networks Based on Particle Filter for Object Tracking, „IEEE Access” 2020, t.8

Jak wynika z rysunku powyżej bramka wyjściowa sterowana jest przez wektor o_t , a danymi wyjściowymi z komórki są wektory h_t oraz c_t .

Podsumowując, komórka LSTM potrafi rozpoznać istotne informacje pojawiające się w sekwencji wejściowej, zapisać je w pamięci długoterminowej i utrzymywać tak długo, jak to potrzebne. Dzięki działaniu bramki zapominania sieć może samodzielnie decydować, kiedy daną informację usunąć, a dzięki bramce wyjścia – kiedy ją aktywować i wykorzystać. Ta elastyczność sprawia, że LSTM doskonale sprawdza się w zadaniach wymagających uchwycenia zależności rozciągniętych w czasie.³⁷

³⁵ A. Geron, *Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow*, Helion, Gliwice 2020, s.504-505.

³⁶ Ib.

³⁷ Ib.

3.3. XGBoost

XGBoost to niezwykle wydajna implementacja metody gradient boosting na drzewach regresyjnych. Wyróżnia się tym, że łączy ze sobą przyrostowe uczenie z wykorzystaniem drugich pochodnych, regularyzację celu oraz różnorodne optymalizacje dzięki którym osiąga wyższą dokładność w połączeniu z szybkim trenowaniem modeli.

W drzewach decyzyjnych ostateczny predyktor budowany jest jako suma wielu prostych funkcji–drzew. Każde drzewo dzieli przestrzeń zmiennych wejściowych na obszary (liście), w których przechowywana jest wartość predykcji; ten mechanizm hierarchicznych podziałów pozwala modelowi wychwytywać zarówno nieliniowe, jak i interakcyjne zależności między cechami. Drzewa typu CART, cechują się szeregiem zalet: są szybkie do konstruowania, naturalnie obsługują mieszane typy zmiennych i wartości brakujące, nie wymagają wstępnego skalowania danych, a dzięki automatycznemu wyborowi zmiennych w procesie podziałów – odporne są na wiele nieistotnych cech.³⁸

W omawianej technice końcowy model stanowi sumę K kolejnych drzew regresyjnych, z których każde kolejne drzewo uczy się jak naprawiać poprzednie błędy popełnione przez dotychczasowy zbiór modeli. Wynikiem tego jest skupienie się nowo powstałego drzewa na najgorszych predykcjach poprzednich modeli, co stopniowo poprawia jakość prognoz.

Podstawą uczenia się w tej technice jest zastosowanie minimalizacyjnej funkcji celu, składającej się z tzw. kary za złożoność każdego drzewa oraz straty na danych.³⁹

Wspomniana funkcja celu została przedstawiona poniżej.

$$\mathcal{L}(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k) \quad (12)$$

Gdzie:

- $\Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2$,
- l – różniczkowalna wypukła funkcja straty,
- $\Omega(f)$ – „kara” za złożoność pojedynczego drzewa f , człon regularyzacyjny,

³⁸ J. Friedman, T. Hastie, R. Tibisharani, Additive Models, Trees, and Related Methods, (w:) „The Elements of Statistical Learning: Data Mining, Inference and Prediction”, Springer, Nowy Jork 2008, s. 11-13.

³⁹ T. Chen, C. Guestrin XGBoost: *A Scalable Tree Boosting System*, (w:) „Proceedings of the 22nd AVM SIGDD International Conference on Knowledge Discovery and Data Mining” 2016, s. 1-9.

- γ – współczynnik „karzący”,
- T – liczba liści w danym drzewie,
- λ – współczynnik regularyzacji L2,
- w – wektor wag przypisanych poszczególnym liściom.

W każdej iteracji t funkcję celu przybliża się do drugiego rzędu szeregu Taylora, co jest zobrazowane poniżej.

$$\tilde{\mathcal{L}}^{(t)} = \sum_{i=1}^n \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t(x_i)^2 \right] + \Omega(f_t) \quad (13)$$

Gdzie g_i jest gradientem straty względem predykcji z poprzedniej iteracji, natomiast h_i to druga pochodna tej samej straty, a $f_t(x_i)$ to wartość przewidywana przez nowo dodane drzewo i $\Omega(f_t)$ to człon regularyzacyjny. Przedstawione podejście pozwala na efektywne obliczenie optymalnych wag liści (w) oraz odpowiadającym im przyrostom zysku gain dla potencjalnych podziałów.⁴⁰

Do wyszukiwania najlepszych progów podziału XGBoost stosuje dwie metody. Jedną z nich jest dokładne sprawdzenie wszystkich możliwych punktów cięcia tzw. „exact greedy”, a kolejną metodą jest przybliżone podejście oparte na metodzie ważonych kwantyli (ang. weighted quantile sketch), która wyznacza kandydatów na progi z kontrolowaną tolerancją błędów. Oprócz tego, XGBoost wykorzystuje format kolumnowy podzielony na bloki, co umożliwia równoległe obliczanie gradientów i drugich pochodnych strat z minimalną komunikacją między wątkami.⁴¹

⁴⁰ T. Chen, C. Guestrin XGBoost: *A Scalable Tree Boosting System*, (w:) „Proceedings of the 22nd AVM SIGDD International Conference on Knowledge Discovery and Data Mining” 2016, s. 1-9.

⁴¹ Ib.

3.4. Model hybrydowy – GARCH-GRU

W literaturze dotyczącej prognozowania zmienności coraz bardziej popularnym zjawiskiem jest wykorzystywanie modeli hybrydowych – jako połączenie technik ekonometrycznych oraz algorytmów uczenia maszynowego. Wyróżnianych jest kilka typów modeli hybrydowych: PBH (ang. Preprocessing-Based Hybrid Model), OBH (ang. Optimization-Based Hybrid Model), CBH (Components-Based Hybrid Model) oraz SBH (ang. Postprocessing-Based Hybrid Model). Do wykonania analizy w niniejszej pracy wybrano strukturę CBH, w wariancie hybrydyzacji szeregowej modelu GARCH oraz GRU. Kluczową ideą modeli CBH jest wykorzystanie mocnych stron poszczególnych modeli w celu zwiększenia skuteczności prognozowania. Jest to najczęściej zestawienie modelu liniowego, który powinien być modelem statystycznym, z nieliniowym, który jest modelem inteligentnym.⁴² Poniżej został przedstawiony graf reprezentujący strukturę hybrydowego modelu CBH.



Rysunek 7 Ramowy model szeregowego CBH

Źródło: opracowanie własne dla podstawie: Z. Hajirahimi, M. Khashei, Hybridization of hybrid structures for time series forecasting: a review, „Artificial Intelligence Review” 2022.

W niniejszej pracy model działa w następujący sposób: najpierw budowany jest model GARCH, który stara się uchwycić główne, liniowe wzorce w danych; a następnie sieć neuronowa GRU wykorzystuje tę prognozę, jak i również logarytmiczne stopy zwrotu jako cechy wejściowe – co pozwala na uchwycenie nieliniowych wzorców.


Jednym z komponentów modelu hybrydowego jest model GARCH, którego szczegółowa charakterystyka została przedstawiona w Rozdziale (3.2.). W związku z tym w poniższej części skoncentrowano się na drugim składniku wykorzystywanego modelu, jakim jest sieć neuronowa GRU.

GRU, czyli Gated Recurrent Unit jest tak naprawdę zredukowaną wersją architektury LSTM, która mimo prostszej struktury oferuje zbliżoną skuteczność.⁴³

⁴² Z. Hajirahimi, M. Khashei, Hybridization of hybrid structures for time series forecasting: a review, „Artificial Intelligence Review” 2022, nr 56, s. 1206-1214.

⁴³ A. Geron, *Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow*, Helion, Gliwice 2020, s.506-507.

Poniżej przedstawiono rysunek obrazujący strukturę komórki GRU, na bazie którego została wytłumaczona architektura i działanie modelu.



Rysunek 8 Pojedyncza komórka sieci GRU

Źródło: A.Riaz, M. Khan, M. Nabeel, H. Jamil, SBAG: A Hybrid Deep Learning Model for Large Scale Traffic Speed Prediction, „International Journal of Advanced Computer Science and Applications” vol. 11, n. 1, 2020

Przedstawiona powyżej komórka GRU składa się z bramki aktualizacji, której wektorem jest z_t ; bramki resetującej, której wektorem jest r_t oraz bramki głównej, której wektorem jest $\tilde{h}_t$. Dwie pierwsze bramki odpowiadają za kontrolowanie przepływu informacji między krokami czasowymi, ale każda z nich pełni inną funkcję. Bramki aktualizacji umożliwiają sieci decydowanie w jakim stopniu przeszłe informacje mają być zachowane lub zastąpione nowymi. Mechanizm ten pozwala na dynamiczne balansowanie między kopiowaniem poprzedniego stanu, a jego odświeżeniem. Natomiast bramka resetująca kontroluje, które części przeszłego stanu są istotne przy wyznaczaniu nowego. Pozwala to na tymczasowe „ignorowanie” części informacji ze stanu przeszłego, czego wynikiem jest możliwość uczenia się złożonych nieliniowych zależności w czasie.⁴⁴

W celu pełnego zobrazowania mechanizmu działania sieci GRU, poniżej przedstawiono równania opisujące obliczenia wykonywane wewnątrz pojedynczej komórki zobrazowanej na powyższym rysunku.

⁴⁴ I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, Springer, 2016, s.411-412.

$$z_t = \sigma(W_{xz}^T x_{(t)} + W_{hz}^T h_{(t-1)} + b_z) \quad (14)$$

$$r_t = \sigma(W_{xr}^T x_{(t)} + W_{hr}^T h_{(t-1)} + b_r) \quad (15)$$

$$\tilde{h}_t = \tanh(W_{x\tilde{h}}^T x_{(t)} + W_{h\tilde{h}}^T (r_t \otimes h_{(t-1)}) + b_{\tilde{h}}) \quad (16)$$

$$h_t = z_t \otimes \tilde{h}_t + (1 - z_t) \otimes h_{(t-1)} \quad (17)$$


Gdzie:

- $\tilde{h}_t$ – wartość wektora warstwy głównej w chwili t ;
- z_t – wartość wektora bramki aktualizacji w chwili t ;
- r_t – wartość wektora bramki resetującej w chwili t ;
- σ – funkcja sigmoidalna;
- $\tanh$ - funkcja tangens hiperboliczny;
- W_{xr}^T, W_{xz}^T - macierze wag warstwy aktualizacji i warstwy resetującej dla jej połączenia z wektorem $x^{(t)}$;
- W_{hr}^T, W_{hz}^T - macierze wag warstwy aktualizacji i warstwy resetującej dla jej połączenia z poprzednim stanem krótkotrwałym $h_{(t-1)}$;
- $x_{(t)}$ – wartość wektora wejściowego w chwili t ;
- $h_{(t-1)}$ – wartość wektora ukrytego w chwili $t-1$;
- $\otimes$ - znak iloczynu.⁴⁵

Na tym zakończono opis architektury GRU oraz jej mechanizmów działania. Finalnie, model GARCH przyjmuje jako zmienną wejściową logarytmiczna stopę zwrotu, a zmienną wyjściową jest prognozowana zmienność warunkowa, która jednocześnie jest zmienną wejściową, wraz z logarytmicznymi stopami zwrotu do modelu GRU. Celem modelu GRU jest wygenerowanie predykcji zmienności, rozumianej jako jednodniowa wartość zmienności obliczona metodą kroczącą.

Całkowitą strukturę przepływu informacji przedstawia poniższy rysunek.

⁴⁵ A. Geron, *Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow*, Helion, Gliwice 2020, s.506-507.



Rysunek 9 Struktura modelu GARCH-GRU. Gdzie $r_{1:t}$ oznacza wektor logarytmicznych stóp zwrotu, $\hat{\sigma}_{1:t}^{GARCH}$ oznacza prognozowaną zmienność warunkową z modelu GARCH, a $\hat{\sigma}_{t+1}$ oznacza finalną prognozę zmienności uzyskaną z sieci GRU.

Źródło: Opracowanie własne zainspirowane z J. Michańków, Ł. Kwiatkowski, J. Morajda, *Combining Deep Learning and GARCH Models for Financial Volatility and Risk Forecasting*,

3.5. Metody oceny jakości prognoz

W niniejszym podrozdziale omówione zostaną stosowane w niniejszej pracy miary oceny jakości prognoz - *RMSE*, *MAPE* oraz współczynnik determinacji R^2 - których celem jest wybranie metody prognostycznej najlepiej dopasowanej do analizowanego problemu. Poniżej przedstawiono wzory tych miar.

- Pierwiastek średniego błędu kwadratowego

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2} \quad (18)$$

RMSE to pierwiastek kwadratowy ze średniej arytmetycznej kwadratów różnic między wartościami prognozowanymi a rzeczywistymi. Wskaźnik ten silnie reaguje na większe odchylenia, ponieważ błędy podnoszone są do kwadratu przed uśrednieniem, nadając im większą wagę. Wartość *RMSE* jest zawsze nieujemna, a wynik równy zero oznaczałby idealne dopasowanie modelu do danych.⁴⁶

- Średni procentowy błąd bezwzględny

⁴⁶ M. Sahiner, *Forecasting volatility in Asian financial markets: Evidence from recursive and rolling window methods*, „Journal of Economics, Finance and Accounting Studies” 2022, t. 2, nr 157, s. 10-13.

$$MAPE = \frac{100\%}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| \quad (19)$$

MAPE to miara, która obliczana jest jako średnia wartość procentowych błędów prognozy, przy czym każdy błąd jest dzielony przez rzeczywistą wartość w danym okresie. Jej zaletą jest łatwość interpretacji oraz możliwość bezpośredniego porównywania jakości różnych modeli prognostycznych zmienności.⁴⁷

- Współczynnik determinacji R^2

$$R^2 = 1 - \frac{\sum_{t=1}^n (y_t - \hat{y}_t)^2}{\sum_{t=1}^n (y_t - \bar{y}_t)^2} \quad (20)$$

Współczynnik determinacji R^2 informuje o proporcji zmienności zmiennej objaśnianej przez model w stosunku do całkowitej zmienności obserwowanej. Wartość współczynnika bliska 1 oznacza wysoką jakość dopasowania, a wartość bliska 0 informuje o braku dopasowania.⁴⁸ Natomiast wartości ujemne wskazują, że model prognozuje gorzej niż średnia wartość zbioru uczącego.

⁴⁷ M. Sahiner, *Forecasting volatility in Asian financial markets: Evidence from recursive and rolling window methods*, „Journal of Economics, Finance and Accounting Studies” 2022, t. 2, nr 157, s. 10-13.

⁴⁸ [R-Squared: Definition, Calculation, and Interpretation](#), [dostęp: 05.06.2025].

4. Realizacja eksperymentu empirycznego z wykorzystaniem modeli prognostycznych

Na wstępnym etapie analizy przygotowano zbiór danych, stanowiący podstawę dla implementacji wszystkich modeli prognostycznych opisanych w niniejszym rozdziale. Wykorzystano dzienne ceny zamknięcia spółki PKO Bank Polski oraz indeksu WIG-Banki, które przekształcono do logarytmicznych stóp zwrotu, oczyszczono z dni wolnych od sesji giełdowych oraz uzupełniono braki danych metodą forward-fill. Dane zostały następnie podzielone na pięć wyróżnionych okresów rynkowych oraz trzy warianty okna kroczącego (5, 10- i 20-dniowego), co pozwoliło na obliczenie zmienności referencyjnej. Szczegółowe uzasadnienie tych kroków zawarto w podrozdziałach 2.3 i 2.4.

Pełny kod źródłowy zaimplementowanych modeli umieszczono w repozytorium github, które można znaleźć pod linkiem:

https://github.com/Zuzia416553/volatility_prediction .


4.1. Implementacja modelu GARCH(1,1)

W ramach badania empirycznego zastosowano model GARCH(1,1) do prognozowania zmienności na podstawie logarytmicznych stóp zwrotu spółki PKO Bank Polski oraz indeksu WIG-Banki. Do estymacji wykorzystano funkcję *arch_model* z pakietu *arch* w języku *Python*, przyjmując założenie zerowej średniej procesu oraz normalności rozkładu reszt. Model był estymowany oddzielnie dla każdego wyróżnionego okresu oraz okien kroczących. W każdym przypadku obliczono zmienność jako odchylenie standardowe logarytmicznych stóp zwrotu, a następnie prognozowano zmienność jednodniową w przód tzw. prognoza day-to-day. Zmienna wejściowa w modelu była wektorem logarytmicznych stóp zwrotu z danego okresu, natomiast zmienną wyjściową – prognozowana zmienność warunkowa na kolejny dzień, która następnie porównywana była ze zmiennością rzeczywistą.

Wyniki estymacji przedstawiono na wykresach, które umożliwiają wizualną ocenę dopasowania modelu – poprzez porównanie wartości prognozowanej zmienności z rzeczywistą zmiennością obliczoną ex post (na podstawie kroczącego odchylenia standardowego). Prognozy generowane były ex ante, tj. w sposób sekwencyjny, wyłącznie na podstawie informacji dostępnych do danego momentu. Zakres prognozy obejmuje ostatnie 10% danych w każdej próbce, co w praktyce oznacza horyzont około

50 dni – z niewielkimi różnicami wynikającymi z długości danego okresu analizy. Dla tych przedziałów prognoz wygenerowano wizualizacje oraz wyliczono miary jakości prognoz, takie jak RMSE, MAPE i R^2 , które zostały szczegółowo omówione w rozdziale 5.


Poniżej przedstawiono wykresy prognoz zmienności uzyskanych przy użyciu modelu GARCH(1,1) dla spółki PKO Bank Polski oraz indeksu WIG – stanowią one wynik końcowy procesu estymacji i prognozowania, obrazując dopasowanie modelu do danych empirycznych w różnych warunkach rynkowych.



Rysunek 10 Prognozy GARCH(1,1) jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) dla spółki PKO. Linia niebieska przedstawia prognozowaną zmienność, a linia szara – wartość rzeczywistą.

Źródło: Opracowanie własne

Prognozy zmienności przez GARCH(1,1) dla indeksu WIG-Banki w różnych okresach i oknach czasowych



Rysunek 11 Prognozy GARCH(1,1) jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) indeksu WIG-Banki. Linia niebieska przedstawia prognozowaną zmienność, a linia szara – wartość rzeczywistą.

Źródło: Opracowanie własne

4.2. Implementacja modelu LSTM

W badaniu empirycznym wykorzystano również model LSTM. Obróbka danych przebiegała zgodnie z opisanym we wstępie procesem. Dane poddane procesom przygotowawczym następnie podzielono na trzy zestawy: uczący, który wynosił 80% zestawu; walidacyjny- wynoszący 10% oraz testowy, obejmujący pozostałe 10% danych. Zmienne wejściowe (x) zostały wyrażone jako logarytmiczne stopy zwrotu, natomiast zmienne wyjściowe (y) jako zmienność warunkowa w kolejnym dniu.

Model został zaimplementowany w języku *Python* z użyciem biblioteki *TensorFlow*. W skład sieci wchodziło od jednej do trzech warstw LSTM, zakończonych warstwą *Dense* z jednym neuronem wyjściowym. Każda warstwa została wyposażona w funkcję aktywacji *tanh* oraz mechanizm *dropout* w celu ograniczenia przeuczenia. Sieć trenowano z wykorzystaniem optymalizatora Adam, a funkcja kosztu był średni błąd kwadratowy. Dodatkowo zastosowano mechanizm wczesnego zatrzymania (*early stopping*) z monitorowaniem błędu walidacyjnego i automatycznym przywracaniem najlepszych wag modelu.

Dobór optymalnej konfiguracji hiperparametrów modelu LSTM przeprowadzono przy użyciu metody eksperymentalnej, wykorzystując technikę przeszukiwania siatki hiperparametrów (*grid search*). Procedura ta polega na systematycznym testowaniu wszystkich możliwych kombinacji zadanych wartości hiperparametrów. Mimo iż podejście to jest relatywnie czasochłonne, pozwala ono na wyczerpujące przeszukanie przestrzeni hiperparametrów, co zwiększa prawdopodobieństwo znalezienia optymalnego modelu.⁴⁹

Poniżej przedstawiono zestaw hiperparametrów wykorzystany w pracy:

- Liczba neuronów (*units*) – odpowiada za rozmiar wewnętrznej reprezentacji warstwy LSTM, przyjęto wartości 64 oraz 128;
- Liczba warstw (*layers*) – określa głębokość modelu, przyjęto wartości 1, 2 i 3;
- Długość sekwencji (*sequence length*) – definiuje liczbę kolejnych obserwacji wejściowych, przyjęto wartości 5, 10 i 20;
- Liczba epok (*epochs*) – liczba przebiegów treningowych modelu, przyjęto wartości 20, 40, 60 oraz 80;
- Wielkość partii (*batch*) – liczba próbek wykorzystywanych do jednorazowej aktualizacji wag, przyjęto wartości 8 i 16;

⁴⁹ [Hyperparameter Tuning - GeeksforGeeks](#) [dostęp: 01.06.2025]

- Współczynnik uczenia (*learning rate*) – tempo dostosowywania wag modelu, przyjęto wartości 0,01 oraz 0,001;
- Wartość dropout – technika regularyzacji, polegająca na losowym wyłączaniu neuronów, przyjęto wartości 0 oraz 0,2;

Wartości powyższych hiperparametrów dobrano w oparciu o zalecenia zawarte w poradniku *A Guide to LSTM Hyperparameter Tuning for Optimal Model Training*⁵⁰ oraz praktyk ugruntowanych w zadaniach regresyjnych LSTM.

Na podstawie wyników jakości prognoz uzyskanych na zbiorze testowym wybrano te konfiguracje, które osiągnęły najniższe wartości błędów predykcji. Finalne wartości hiperparametrów zastosowane w modelach przedstawiają konfiguracje, które okazały się najskuteczniejsze w przewidywaniu zmienności z badanych okresach na różnych długościach przesuwanego okna. Ich szczegółowa charakterystyka przedstawiona jest w tabelach poniżej.

Tabela 3 Najlepsze konfiguracje hiperparametrów modeli LSTM dla spółki PKO Bank Polski w oknie 5-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba neuronów	128	128	128	128	128
Liczba epok	60	40	80	60	20
Liczba epok wykonanych z „early stop'em”	60	13	80	60	20
Wielkość partii	8	16	8	16	8
Długość sekwencji	10	20	10	5	5
Liczba warstw	1	3	2	1	3
Współczynnik uczenia	0,001	0,001	0,001	0,001	0,001
Wartość dropout	0	0,2	0	0	0

Źródło: Opracowanie własne

⁵⁰ [A Guide to LSTM Hyperparameter Tuning for Optimal Model Training | by HIYA CHATTERJEE | Medium](#) [dostęp: 04.05.2025]

Tabela 4 Najlepsze konfiguracje hiperparametrów modeli LSTM dla spółki PKO Bank Polski w oknie 10-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba neuronów	128	128	128	128	128
Liczba epok	60	80	80	60	40
Liczba epok wykonanych z „early stop’em”	60	74	80	60	40
Wielkość partii	8	8	8	16	16
Długość sekwencji	10	10	10	5	5
Liczba warstw	1	2	1	2	1
Współczynnik uczenia	0,001	0,001	0,001	0,001	0,001
Wartość dropout	0,2	0,2	0	0,2	0

Źródło: Opracowanie własne

Tabela 5 Najlepsze konfiguracje hiperparametrów modeli LSTM dla spółki PKO Bank Polski w oknie 20-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba neuronów	128	128	128	128	128
Liczba epok	40	60	40	20	20
Liczba epok wykonanych z „early stop’em”	35	13	40	14	13
Wielkość partii	8	16	8	8	16
Długość sekwencji	20	20	10	10	20
Liczba warstw	1	2	2	3	2
Współczynnik uczenia	0,001	0,001	0,001	0,001	0,001
Wartość dropout	0	0,2	0,2	0,2	0

Źródło: Opracowanie własne

Tabela 6 Najlepsze konfiguracje hiperparametrów modeli LSTM dla indeksu WIG-Banki w oknie 5-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba neuronów	128	128	128	128	128
Liczba epok	80	20	80	80	80
Liczba epok wykonanych z „early stop’em”	80	14	80	80	13
Wielkość partii	16	16	8	16	16
Długość sekwencji	20	20	10	5	5
Liczba warstw	2	3	2	2	3
Współczynnik uczenia	0,001	0,001	0,001	0,001	0,001
Wartość dropout	0	0,2	0	0	0

Źródło: Opracowanie własne

Tabela 7 Najlepsze konfiguracje hiperparametrów modeli LSTM dla indeksu WIG-Banki w oknie 10-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba neuronów	128	128	128	128	128
Liczba epok	80	60	80	80	40
Liczba epok wykonanych z „early stop'em”	80	60	80	80	40
Wielkość partii	16	8	16	16	16
Długość sekwencji	10	10	10	5	5
Liczba warstw	2	2	2	1	1
Współczynnik uczenia	0,001	0,001	0,001	0,001	0,001
Wartość dropout	0,2	0,2	0,2	0,2	0,2

Źródło: Opracowanie własne


Tabela 8 Najlepsze konfiguracje hiperparametrów modeli LSTM dla indeksu WIG-Banki w oknie 20-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba neuronów	128	128	128	128	128
Liczba epok	80	20	60	60	40
Liczba epok wykonanych z „early stop'em”	59	13	60	14	13
Wielkość partii	8	16	16	8	8
Długość sekwencji	20	20	20	5	10
Liczba warstw	1	2	2	3	1
Współczynnik uczenia	0,001	0,001	0,001	0,001	0,001
Wartość dropout	0,2	0,2	0	0,2	0

Źródło: Opracowanie własne

Wyniki predykcji przedstawiono na wykresach, które prezentują porównanie zmienności rzeczywistej i prognozowanej. Predykcja w przypadku LSTM również obejmuje 10% ostatnich obserwacji, czyli około 50 dni. Poniżej zaprezentowano wizualizacje dla spółko PKO Bank Polski oraz indeksu WIG-Banki.


Prognozy zmienności przez LSTM dla spółki PKO w różnych okresach i oknach czasowych



Rysunek 12 Prognozy LSTM jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) spółki PKO. Linia niebieska przedstawia prognozowaną zmienność, a linia szara – wartość rzeczywistą.

Źródło: Opracowanie własne

Prognozy zmienności przez LSTM dla indeksu WIG-Banki w różnych okresach i oknach czasowych



Rysunek 13 Prognozy LSTM jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) indeksu WIG-Banki. Linia niebieska przedstawia prognozowaną zmienność, a linia szara – wartość rzeczywistą.

Źródło: Opracowanie własne

4.3. Implementacja modelu XGBoost

W badaniu empirycznym uwzględniono także model XGBoost, stanowiący zaawansowaną technikę uczenia nadzorowanego opartą na wzmocnieniu gradientowym. Dane przygotowano analogicznie jak we wcześniejszych analizach: wykorzystano logarytmiczne stopy zwrotu z dziennych cen zamknięcia, przefiltrowane z uwzględnieniem kalendarza sesyjnego GPW oraz uzupełnione metodą forward-fill. Dla każdego wyróżnionego okresu zastosowano trzy długości kroczących okien: 5-, 10- i 20-dniowe.

W modelu XGBoost zmienną wejściową (x) stanowiły historyczne sekwencje logarytmicznych stóp zwrotu, natomiast zmienną wyjściową (y) była zmienność w kolejnym dniu. Sekwencje wejściowe tworzone poprzez agregację kolejnych wartości wejściowych zgodnie z przyjętą długością sekwencji.

Model XGBoost zaimplementowano z użyciem biblioteki *xgboost* w środowisku *Python*. W każdym przypadku zastosowano regresję kwadratową jako funkcję celu. W celu doboru najskuteczniejszych parametrów modelu przeprowadzono proces przeszukiwania siatki hiperparametrów (*grid search*), badając wszystkie możliwe kombinacje zadanych wartości.

Zastosowane hiperparametry i ich zakres:

- Liczba drzew (*numer of estimators*) – liczba estymatorów tworzonych w kolejnych iteracjach boostingowych, przyjęto wartości: 50, 100, 200, 300;
- Maksymalna głębokość drzew (*max depth*) – kontroluje stopień złożoności struktury drzewa, przyjęto wartości: 2, 3, 4, 6;
- Współczynnik uczenia (*learning rate*) – tempo uczenia modelu w kolejnych iteracjach, przyjęto wartości: 0,01; 0,05; 0,1;
- Długość sekwencji (*sequence length*) – liczba dni logarytmicznych stóp zwrotu wykorzystana jako jedna obserwacja, przyjęto wartości: 5, 10, 20;
- Próbkowanie obserwacji (*subsample*) – proporcja próbek losowana do każdej iteracji boostingowej, przyjęto wartości: 0,6; 0,8; 1;
- Proporcja kolumn dla drzewa (*colsample by tree*) – proporcja cech losowana do każdego drzewa, przyjęto wartości: 0,6; 0,8; 1;
- Minimalna waga (*min child weight*) – minimalna waga sumy obserwacji w liściu, przyjęto wartości: 1, 3, 5;

- Współczynnik regularyzacji L2 (*regularization lambda*) – przyjęto wartości: 0,1; 1; 5;
- Współczynnik regularyzacji L2 (*regularization alpha*) – przyjęto wartości: 0; 0,1; 0,5.

Wartości powyższych hiperparametrów dobrano w oparciu o zalecenia zawarte w poradniku *Complete Guide to Parameter Tuning in XGBoost*⁵¹ opublikowanym na blogu Analytics Vidhya oraz praktyk ugruntowanych w zadaniach regresyjnych XGBoost.

Na podstawie uzyskanych wyników na zbiorze testowym wybrano najlepsze modele, tj. te, które osiągnęły najwyższe wartości R^2 lub najniższe błędy predykcji. Szczegółowe konfiguracje tych modeli przedstawiono w tabelach, które zawierają zestawienia dla każdego okresu i okna czasowego osobno.

Tabela 9 Najlepsze konfiguracje hiperparametrów modeli XGBoost dla spółki PKO Bank Polski w oknie 5-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba drzew	100	200	100	200	300
Maksymalna głębokość drzew	2	6	2	6	4
Współczynnik uczenia	0,1	0,01	0,1	0,01	0,1
Długość sekwencji	10	5	10	5	20
Próbkowanie obserwacji	0,6	0,8	0,8	0,8	0,8
Proporcja kolumn dla drzewa	0,6	1	0,6	1	0,8
Minimalna waga	1	5	5	1	5
Współczynnik regularyzacji L2	0,1	5	0,1	1	1
Współczynnik regularyzacji L2	0	0	0	0	0

Źródło: Opracowanie własne

⁵¹ [XGBoost Parameters Tuning: A Complete Guide with Python Codes](#) [dostęp: 06.05.2025].

Tabela 10 Najlepsze konfiguracje hiperparametrów modeli XGBoost dla spółki PKO Bank Polski w oknie 10-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba drzew	200	200	100	200	300
Maksymalna głębokość drzew	2	6	2	6	6
Współczynnik uczenia	0,1	0,01	0,1	0,01	0,1
Długość sekwencji	10	5	10	5	20
Próbkowanie obserwacji	0,8	0,8	0,8	0,8	0,6
Proporcja kolumn dla drzewa	0,8	1	0,6	1	0,6
Minimalna waga	1	5	5	1	5
Współczynnik regularyzacji L2	5	5	0,1	1	5
Współczynnik regularyzacji L2	0	0	0	0	0

Źródło: Opracowanie własne

Tabela 11 Najlepsze konfiguracje hiperparametrów modeli XGBoost dla spółki PKO Bank Polski w oknie 20-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba drzew	300	300	300	200	300
Maksymalna głębokość drzew	3	2	2	2	6
Współczynnik uczenia	0,1	0,1	0,1	0,1	0,1
Długość sekwencji	20	10	20	20	20
Próbkowanie obserwacji	0,6	0,6	0,6	0,8	0,6
Proporcja kolumn dla drzewa	1	0,6	1	1	1
Minimalna waga	5	3	3	3	5
Współczynnik regularyzacji L2	0,1	0,1	1	0,1	1
Współczynnik regularyzacji L2	0	0	0	0	0

Źródło: Opracowanie własne

Tabela 12 Najlepsze konfiguracje hiperparametrów modeli XGBoost dla indeksu WIG-Banki w oknie 5-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba drzew	300	100	300	200	300
Maksymalna głębokość drzew	3	2	6	6	3
Współczynnik uczenia	0,1	0,1	0,1	0,1	0,1
Długość sekwencji	5	10	5	5	20
Próbkowanie obserwacji	0,8	0,6	0,6	0,6	0,6
Proporcja kolumn dla drzewa	0,6	1	0,8	1	1
Minimalna waga	1	1	3	1	5
Współczynnik regularyzacji L2	1	1	1	0,1	0,1
Współczynnik regularyzacji L2	0	0	0	0	0

Źródło: Opracowanie własne

Tabela 13 Najlepsze konfiguracje hiperparametrów modeli XGBoost dla indeksu WIG-Banki w oknie 10-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba drzew	300	200	100	300	300
Maksymalna głębokość drzew	2	2	4	4	4
Współczynnik uczenia	0,1	0,1	0,1	0,01	0,1
Długość sekwencji	10	10	10	10	20
Próbkowanie obserwacji	0,8	0,6	0,6	0,8	0,6
Proporcja kolumn dla drzewa	0,6	1	1	1	0,6
Minimalna waga	1	5	3	5	5
Współczynnik regularyzacji L2	1	0,1	0,1	5	0,1
Współczynnik regularyzacji L2	0	0	0	0	0

Źródło: Opracowanie własne


Tabela 14 Najlepsze konfiguracje hiperparametrów modeli XGBoost dla indeksu WIG-Banki w oknie 20-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba drzew	300	100	300	300	300
Maksymalna głębokość drzew	3	3	6	6	3
Współczynnik uczenia	0,1	0,1	0,1	0,01	0,1
Długość sekwencji	20	10	20	20	20
Próbkowanie obserwacji	0,6	0,8	0,6	0,6	0,8
Proporcja kolumn dla drzewa	0,6	0,6	1	1	0,8
Minimalna waga	3	1	5	5	1
Współczynnik regularyzacji L2	0,1	0,1	5	5	5
Współczynnik regularyzacji L2	0	0	0	0,1	0,1

Źródło: Opracowanie własne

Dla najlepszych modeli przygotowano również wizualizację prognoz, ukazującą porównanie zmienności rzeczywistej oraz prognozowanej w ostatnich 10% dni badanego okresu.


Prognozy zmienności przez XGBoost dla spółki PKO w różnych okresach i oknach czasowych



Rysunek 14 Prognozy XGBoost jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) spółki PKO. Linia niebieska przedstawia prognozowaną zmienność, a linia szara – wartość rzeczywistą.

Źródło: Opracowanie własne

Prognozy zmienności przez XGBoost dla indeksu WIG-Banki w różnych okresach i oknach czasowych



Rysunek 15 Prognozy XGBoost jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) indeksu WIG-Banki. Linia niebieska przedstawia prognozowaną zmienność, a linia szara – wartość rzeczywistą.

Źródło: Opracowanie własne

4.4. Implementacja modelu GARCH-GRU

W ramach badania empirycznego wykorzystano hybrydowy model GARCH-GRU, który łączy klasyczne podejście statystyczne do estymacji zmienności z potencjałem modelu sekwencyjnego do wykrywania nieliniowych zależności czasowych. Model ten został zbudowany w układzie szeregowym: w pierwszym etapie generowano szereg zmienności warunkowej z wykorzystaniem modelu GARCH(1,1), który posłużył jako dodatkowa zmienna wejściowa dla sieci neuronowej GRU.

Dane wejściowe zostały przygotowane zgodnie z wcześniej opisanym procesem, przy czym oprócz logarytmicznych stóp zwrotu, do modelu wprowadzono także estymowaną wariancję warunkową (zmienność GARCH). Zmienną wyjściową była rzeczywista zmienność (rolling volatility) przesunięta o jeden dzień w przód.

Podobnie jak w przypadku innych modeli sekwencyjnych, dane zostały podzielone na zestawy treningowe (80%), walidacyjne (10%) oraz testowe (10%). Przed trenowaniem przeprowadzono skalowanie zmiennych wejściowych i wyjściowych metodą *MinMaxScaler*.

Model sieci neuronowej GRU został zaimplementowany z wykorzystaniem biblioteki *TensorFlow* w języku programowania *Python*. Zbudowano sieci zawierające od jednej do trzech warstw GRU, z opcjonalną regularyzacją oraz zastosowaniem techniki *dropout*. Na końcu każdej sieci znajdowała się warstwa *Dense* o jednym neuronie odpowiedzialnym za predykcję zmienności. Trening prowadzono z wykorzystaniem optymalizatora *Adam*, a jako funkcję kosztu przyjęto średni błąd kwadratowy. W celu uniknięcia przeuczenia zastosowano mechanizm wczesnego zatrzymania (*early stopping*), monitorujący błąd walidacyjny.

Hiperparametry sieci były dobierane metodą eksperymentalną poprzez technikę przeszukiwania siatki (*grid search*). Testowano następujące konfiguracje:

- liczba jednostek GRU (*units*) – odpowiada za rozmiar wewnętrznej reprezentacji warstwy GRU, przyjęto wartości 64 oraz 128;
- liczba warstw (*layers*) – określa głębokość modelu, przyjęto wartości 1, 2 i 3;
- długość sekwencji (*sequence length*) – definiuje liczbę kolejnych obserwacji wejściowych, przyjęto wartości 5, 10 i 20;
- liczba epok (*epochs*) – liczba przebiegów treningowych modelu, przyjęto wartości 40, 60 oraz 80;

- wielkość partii (*batch*) – liczba próbek wykorzystywanych do jednorazowej aktualizacji wag, przyjęto wartości 8 i 16;
- współczynnik uczenia (*learning rate*) – tempo dostosowywania wag modelu, przyjęto wartość 0,001;
- wartość dropout – technika regularyzacji, polegająca na losowym wyłączaniu neuronów, przyjęto wartości 0 oraz 0,2;

Wartości powyższych hiperparametrów dobrano w oparciu o zalecenia zawarte w poradniku *A Guide to LSTM Hyperparameter Tuning for Optimal Model Training*⁵² oraz praktyk ugruntowanych w zadaniach regresyjnych GRU. Wykorzystano poradnik oparty na LSTM, ponieważ GRU jako rekurencyjna sieć neuronowa posiada te same parametry. Szeroki zakres wartości hiperparametrów umożliwił wybór najbardziej dopasowanych konfiguracji do różnych warunków rynkowych i okien czasowych. Każda konfiguracja została oceniona na podstawie metryk predykcji: RMSE, MAPE oraz współczynnika determinacji R^2 , a najlepsze zostały przedstawione w tabelach poniżej.

Tabela 15 Najlepsze konfiguracje hiperparametrów modeli GARCH-GRU dla spółki PKO Bank Polski w oknie 5-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba neuronów	128	128	128	128	128
Liczba epok	80	60	60	40	60
Liczba epok wykonanych z „early stop’em”	59	60	60	40	60
Wielkość partii	8	8	8	8	8
Długość sekwencji	10	5	10	5	10
Liczba warstw	2	3	2	2	1
Współczynnik uczenia	0,001	0,001	0,001	0,001	0,001
Wartość dropout	0,2	0,2	0	0	0

Źródło: Opracowanie własne

⁵² [A Guide to LSTM Hyperparameter Tuning for Optimal Model Training | by HIYA CHATTERJEE | Medium](#) [dostęp: 04.05.2025]

Tabela 16 Najlepsze konfiguracje hiperparametrów modeli GARCH-GRU dla spółki PKO Bank Polski w oknie 10-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba neuronów	128	128	128	128	128
Liczba epok	40	60	80	40	80
Liczba epok wykonanych z „early stop'em”	40	60	80	39	53
Wielkość partii	8	8	8	8	8
Długość sekwencji	10	10	5	5	20
Liczba warstw	1	3	2	2	1
Współczynnik uczenia	0,001	0,001	0,001	0,001	0,001
Wartość dropout	0	0	0	0,2	0,2

Źródło: Opracowanie własne

Tabela 17 Najlepsze konfiguracje hiperparametrów modeli GARCH-GRU dla spółki PKO Bank Polski w oknie 20-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba neuronów	128	128	128	128	128
Liczba epok	80	80	40	80	60
Liczba epok wykonanych z „early stop'em”	80	80	40	80	30
Wielkość partii	8	8	8	16	16
Długość sekwencji	10	5	5	5	5
Liczba warstw	1	3	1	2	2
Współczynnik uczenia	0,001	0,001	0,001	0,001	0,001
Wartość dropout	0	0	0	0	0

Źródło: Opracowanie własne

Tabela 18 Najlepsze konfiguracje hiperparametrów modeli GARCH-GRU dla indeksu WIG-Banki w oknie 5-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba neuronów	128	128	128	128	128
Liczba epok	80	80	80	80	60
Liczba epok wykonanych z „early stop'em”	51	64	60	47	60
Wielkość partii	8	8	8	8	8
Długość sekwencji	10	10	5	5	10
Liczba warstw	2	3	1	2	1
Współczynnik uczenia	0,001	0,001	0,001	0,001	0,001
Wartość dropout	0,2	0	0	0	0

Źródło: Opracowanie własne

Tabela 19 Najlepsze konfiguracje hiperparametrów modeli GARCH-GRU dla indeksu WIG-Banki w oknie 10-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba neuronów	128	128	128	128	128
Liczba epok	80	80	80	40	40
Liczba epok wykonanych z „early stop'em”	80	80	62	40	40
Wielkość partii	16	8	8	16	8
Długość sekwencji	5	20	10	20	20
Liczba warstw	2	2	2	2	2
Współczynnik uczenia	0,001	0,001	0,001	0,001	0,001
Wartość dropout	0	0	0	0	0

Źródło: Opracowanie własne


Tabela 20 Najlepsze konfiguracje hiperparametrów modeli GARCH-GRU dla indeksu WIG-Banki w oknie 20-dniowym

	OKRES 1	OKRES 2	OKRES 3	OKRES 4	OKRES 5
Liczba neuronów	128	128	128	128	128
Liczba epok	40	80	80	40	60
Liczba epok wykonanych z „early stop'em”	18	18	79	40	32
Wielkość partii	8	16	8	16	16
Długość sekwencji	10	20	10	5	5
Liczba warstw	1	1	1	2	1
Współczynnik uczenia	0,001	0,001	0,001	0,001	0,001
Wartość dropout	0	0,2	0	0,2	0

Źródło: Opracowanie własne

W dalszej części rozdziału zaprezentowano wykresy przedstawiające dopasowanie prognozowanej zmienności do zmienności rzeczywistej. Wyniki te umożliwiają ocenę jakości dopasowania modelu do danych oraz efektywności zastosowania architektury hybrydowej.


Prognozy zmienności przez GARCH-GRU dla spółki PKO w różnych okresach i oknach czasowych



Rysunek 16 Prognozy GARCH-GRU jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) spółki PKO. Linia niebieska przedstawia prognozowaną zmienność, a linia szara – wartość rzeczywistą.

Źródło: Opracowanie własne

Prognozy zmienności przez GARCH-GRU dla indeksu WIG-Banki w różnych okresach i oknach czasowych



Rysunek 17 Prognozy GARCH-GRU jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) indeksu WIG-Banki. Linia niebieska przedstawia prognozowaną zmienność, a linia szara – wartość rzeczywistą.

Źródło: Opracowanie własne

5. Ewaluacja i porównanie skuteczności modeli prognostycznych

W niniejszym rozdziale przedstawiono ocenę skuteczności zastosowanych modeli prognostycznych w kontekście predykcji zmienności instrumentów finansowych. Zestawienie wyników modeli przygotowano w oparciu o miary jakości, rozróżniając je na analizowane okresy i długości okien kroczących, aby zachować spójność porównań. Selekcja najlepszych modeli w przypadku sieci neuronowych LSTM i GRU opierała się na początkowej eliminacji modeli wykazujących symptomy przeuczenia (*overfitting*) na podstawie wykresów błędów walidacyjnych, a następnie tak jak dla wszystkich innych grup modeli zawartych w pracy dokonano selekcji na podstawie miar oceny jakości prognoz. Wyniki modeli wybranych w ten sposób przedstawiono w dalszej części rozdziału w formie tabelarycznej.

5.1. Analiza porównawcza wyników

W niniejszym podrozdziale przedstawiono zbiorcze wyniki porównania skuteczności modeli prognostycznych w różnych konfiguracjach danych i horyzontów czasowych. Tabele prezentujące wartości miar $RMSE$, $MAPE$ oraz R^2 zostały pogrupowane według okresów rynkowych oraz długości okna agregacji zmienności. W każdej z tabel pogrubieniem wyróżniono najlepszy wynik dla danej miary w obrębie konkretnego zestawu danych, co umożliwia szybką identyfikację najbardziej efektywnego modelu w danym przypadku.

OKRES 1, ZMIENNOŚĆ TYGODNIOWA

Tabela 21 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 1. przy 5-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	0,8238	0,0042	0,0037	0,0035
	<i>R²</i>	-0,0217	0,3241	0,4656	0,5384
	<i>MAPE</i>	33,8413	23,1004	21,0817	21,3435
WIG-Banki	<i>RMSE</i>	0,6298	0,0037	0,0038	0,0041
	<i>R²</i>	0,0600	0,2229	0,6076	0,4111
	<i>MAPE</i>	44,0444	43,7899	35,7842	42,1116

Źródło: Opracowanie własne

Wyniki porównania modeli dla okresu pierwszego na 5-dniowym oknie zmienności pokazują, że metody uczenia maszynowego znacząco przewyższają klasyczny model GARCH pod względem wszystkich analizowanych miar jakości prognoz. Ujemny współczynnik determinacji w GARCH dla PKO wskazuje na prognozę mniej trafną niż taką z użyciem średniej. Finalnie model GARCH-GRU sprawdził się najlepiej dla spółki PKO, z niewielką przewagą nad XGBoost'em. Natomiast dla indeksu sektorowego ze znacznie niższym MAPE, wyższym R^2 został wskazany model XGBoost.

OKRES 1, ZMIENNOŚĆ DWUTYGODNIOWA

Tabela 22 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 1. przy 10-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	0,6335	0,0021	0,0022	0,0019
	<i>R²</i>	-0,1477	0,7562	0,7481	0,8120
	<i>MAPE</i>	20,3561	8,2643	9,5258	8,8298
WIG-Banki	<i>RMSE</i>	0,4743	0,0022	0,0017	0,0021
	<i>R²</i>	0,1380	0,7854	0,8685	0,8194
	<i>MAPE</i>	28,3375	18,3651	14,5444	17,7017

Źródło: Opracowanie własne

Dla zmienności 10-dniowej, w przypadku modelu GARCH, sytuacja prezentuje się podobnie – model nie sprawdził się w przypadku obu instancji danych. Można przyjąć,

że model najlepiej przewidyjący zmienność spółki PKO to GARCH-GRU, który względem średniego błędu kwadratowego i współczynnika determinacji okazał się najskuteczniejszy, a względem *MAPE* był słabszy od LSTM tylko o około pół procenta. Natomiast dla indeksu najlepszym modelem ewidentnie okazał się XGBoost.

OKRES 1, ZMIENNOŚĆ MIESIĘCZNA

Tabela 23 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 1 przy 20-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	0,4650	0,0012	0,0013	0,0014
	<i>R</i> ²	0,0745	0,7935	0,7622	0,8838
	<i>MAPE</i>	14,9403	5,3489	6,3899	5,7627
WIG-Banki	<i>RMSE</i>	0,3440	0,0017	0,0007	0,0011
	<i>R</i> ²	0,2301	0,5987	0,9284	0,9076
	<i>MAPE</i>	16,3605	10,2809	4,9285	5,9457

Źródło: Opracowanie własne

W pierwszym okresie, przy miesięcznym oknie zmienności, dla spółki PKO Bank Polski najniższe wartości *RMSE* oraz *MAPE* uzyskał model LSTM, natomiast najwyższy współczynnik determinacji osiągnął model GARCH-GRU. W przypadku indeksu WIG-Banki, zdecydowanie najlepsze wyniki pod względem *RMSE*, *MAPE* i *R*² odnotował model XGBoost z bardzo dobrymi wynikami miar jakości.

OKRES 2, ZMIENNOŚĆ TYGODNIOWA

Tabela 24 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 2 przy 5-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	0,7113	0,0045	0,0047	0,0048
	<i>R</i> ²	-0,9108	0,0028	0,2569	0,2124
	<i>MAPE</i>	71,3060	41,6817	39,4761	41,2338
WIG-Banki	<i>RMSE</i>	0,4578	0,0030	0,0030	0,0030
	<i>R</i> ²	-0,4389	-0,0133	0,2793	0,3032
	<i>MAPE</i>	70,1431	35,4633	35,5671	34,1755

Źródło: Opracowanie własne

W drugim okresie, przy tygodniowym oknie zmienności, najlepsze wyniki dla spółki PKO Bank Polski pod względem *RMSE* oraz *MAPE* osiągnął model LSTM, jednak wszystkie modele charakteryzują się niskimi wartościami współczynnika determinacji, co wskazuje na ograniczoną zdolność do wyjaśniania zmienności w danych testowych. Dla indeksu WIG-Banki najniższe *RMSE* uzyskały modele LSTM, XGBoost oraz GARCH-GRU (osiągając identyczne wyniki), a najniższy *MAPE* zanotował model GARCH-GRU. Jednak również tutaj wartości są niskie lub ujemne, co sugeruje trudności modeli w adekwatnym odwzorowaniu rzeczywistych zmian zmienności w tym okresie.

OKRES 2, ZMIENNOŚĆ DWUTYGODNIOWA

Tabela 25 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 2 przy 10-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	0,5710	0,0035	0,0047	0,0031
	<i>R²</i>	-1,8780	0,2725	0,2569	0,4085
	<i>MAPE</i>	45,9856	25,4442	39,4761	22,2593
WIG-Banki	<i>RMSE</i>	0,3222	0,0015	0,0017	0,0013
	<i>R²</i>	-0,3148	0,6115	0,5188	0,6384
	<i>MAPE</i>	37,1860	13,0003	13,7023	11,2326

Źródło: Opracowanie własne

W powyższej kombinacji okresu drugiego z dwutygodniowym oknem zmienności, najlepsze wyniki dla spółki PKO uzyskał model GARCH-GRU, który osiągnął najniższe wartości *RMSE* i *MAPE* oraz najwyższy *R²*. Dla indeksu WIG-Banki najskuteczniejszy okazał się również model GARCH-GRU, który wykazał się zarówno najniższymi błędami prognoz, jak i najwyższą wartością współczynnika determinacji, co wskazuje na relatywnie wysoką jakość dopasowania prognoz do rzeczywistej zmienności.

OKRES 2, ZMIENNOŚĆ MIESIĘCZNA

Tabela 26 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 2 przy 20-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	0,5093	0,0025	0,0026	0,0016
	<i>R</i> ²	-4,3442	0,0401	-0,1047	0,5482
	<i>MAPE</i>	37,6394	15,8279	15,7193	10,5548
WIG-Banki	<i>RMSE</i>	0,2261	0,0016	0,0016	0,0007
	<i>R</i> ²	-0,1488	0,0389	-0,0617	0,8269
	<i>MAPE</i>	22,3503	12,6946	13,2083	5,1532

Źródło: Opracowanie własne

W okresie drugim, przy miesięcznym oknie zmienności, model GARCH-GRU uzyskał zdecydowanie najlepsze rezultaty zarówno dla spółki PKO Bank Polski, jak i indeksu WIG-Banki – osiągając najniższe wartości *RMSE* i *MAPE* oraz najwyższe współczynniki determinacji. Jednocześnie obserwuje się wyraźny rozstrzał w jakości prognoz pomiędzy modelami, co wskazuje, że w analizowanym okresie modele hybrydowe istotnie przewyższają nad resztą analizowanych modeli.

OKRES 3, ZMIENNOŚĆ TYGODNIOWA

Tabela 27 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 3 przy 5-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	0,6794	0,0049	0,0055	0,0046
	<i>R</i> ²	-0,0376	-0,0037	-0,2918	0,1033
	<i>MAPE</i>	49,8702	46,0300	59,0012	45,8578
WIG-Banki	<i>RMSE</i>	0,6055	0,0047	0,0045	0,0047
	<i>R</i> ²	-0,0432	0,1939	0,2924	0,2190
	<i>MAPE</i>	81,5230	91,1359	69,7550	81,7803

Źródło: Opracowanie własne

W przypadku prognozowania tygodniowej zmienności w okresie 3, najlepszą skuteczność dla spółki PKO Bank Polski uzyskał ponownie model GARCH-GRU, osiągając najniższe wartości *RMSE* i *MAPE* oraz najwyższy współczynnik determinacji. Dla indeksu WIG-Banki nie występuje jednoznaczny lider – różnice pomiędzy modelami

są niewielkie. W obu zestawach danych wyniki nie są jednak zadowalające i wskazują na ogólną trudność uczenia się modeli w tym okresie.

OKRES 3, ZMIENNOŚĆ DWUTYGODNIOWA

Tabela 28 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 3 przy 10-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	0,4231	0,0029	0,0055	0,0025
	<i>R</i> ²	0,0539	-0,0195	-0,2918	0,2182
	<i>MAPE</i>	20,5884	20,5433	59,0012	17,4776
WIG-Banki	<i>RMSE</i>	0,3722	0,0030	0,0026	0,0028
	<i>R</i> ²	0,1533	0,4193	0,5537	0,4773
	<i>MAPE</i>	32,8438	37,1920	31,7316	32,8902

Źródło: Opracowanie własne

Analizując prognozy dwutygodniowej zmienności dla okresu 3, dla spółki PKO Bank Polski najlepsze wyniki osiągnął model GARCH-GRU. W przypadku indeksu WIG-Banki model XGBoost zanotował najniższy *RMSE* i *MAPE* oraz najwyższą wartość współczynnika determinacji, co czyni go najbardziej skutecznym spośród analizowanych w predykcji zmienności w tym horyzoncie czasowym, mimo średnich wyników metryk.

OKRES 3, ZMIENNOŚĆ MIESIĘCZNA

Tabela 29 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 3 przy 20-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	0,3068	0,0017	0,0017	0,0015
	<i>R</i> ²	0,0850	-0,0063	-0,6838	0,2733
	<i>MAPE</i>	14,8643	9,6426	10,9742	9,1665
WIG-Banki	<i>RMSE</i>	0,2250	0,0016	0,0015	0,0014
	<i>R</i> ²	0,3902	0,4301	0,4700	0,6373
	<i>MAPE</i>	15,2995	16,3761	15,5775	12,9525

Źródło: Opracowanie własne

W przypadku miesięcznego horyzontu zmienności w okresie 3, uzyskane wyniki są stosunkowo zadowalające, zwłaszcza dla modelu GARCH-GRU, który zdecydowanie zdominował pozostałe modele pod względem wszystkich trzech miar jakości prognoz zarówno dla spółki PKO Bank Polski, jak i indeksu WIG-Banki. Zarówno niskie wartości *RMSE* i *MAPE*, jak i najwyższy współczynnik determinacji wskazują na przewagę hybrydowego podejścia w dłuższym oknie prognozy zmienności.

OKRES 4, ZMIENNOŚĆ TYGODNIOWA

Tabela 30 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 4 przy 5-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	0,8394	0,0083	0,0079	0,0074
	<i>R</i> ²	-0,4024	0,1508	0,2225	0,3202
	<i>MAPE</i>	56,8938	54,2763	49,2909	38,6039
WIG-Banki	<i>RMSE</i>	0,8279	0,0081	0,0069	0,0080
	<i>R</i> ²	-0,4733	0,1161	0,3565	0,1428
	<i>MAPE</i>	70,7603	67,6867	51,0724	56,5474

Źródło: Opracowanie własne

W przypadku pięciodniowego okna zmienności w okresie czwartym, uzyskane rezultaty są umiarkowane – wartości *RMSE* oraz *MAPE* wskazują na przeciętną precyzję prognoz, a wartości *R*² pozostają na relatywnie niskim poziomie. Niemniej jednak, analiza wszystkich miar jakości prognostycznej jednoznacznie identyfikuje model GARCH-GRU jako najbardziej efektywny w prognozowaniu zmienności PKO Bank Polski, natomiast dla indeksu WIG-Banki najlepsze rezultaty osiąga model XGBoost.

OKRES 4, ZMIENNOŚĆ DWUTYGODNIOWA

Tabela 31 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 4 przy 10-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	0,4678	0,0039	0,0079	0,0041
	<i>R</i> ²	-0,1388	0,3774	0,2225	0,3318
	<i>MAPE</i>	26,9033	19,2025	49,2909	18,9577
WIG-Banki	<i>RMSE</i>	0,4788	0,0040	0,0034	0,0038
	<i>R</i> ²	-0,1640	0,3587	0,4136	0,3252
	<i>MAPE</i>	32,8207	22,6266	18,5327	17,1950

Źródło: Opracowanie własne

Z perspektywy wyników uzyskanych dla okna dziesięciodniowego w okresie 4, należy stwierdzić, że model LSTM wykazał największą skuteczność w prognozowaniu zmienności dla spółki PKO. W przypadku indeksu WIG-Banki, najbardziej satysfakcjonujące rezultaty odnotowano dla modelu XGBoost, który osiągnął najniższe *RMSE* i najkorzystniejszy poziom współczynnika determinacji, choć model GARCH-GRU charakteryzuje się konkurencyjnymi wartościami błędów.

OKRES 4, ZMIENNOŚĆ MIESIĘCZNA

Tabela 32 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 4 przy 20-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	0,4051	0,0022	0,0024	0,0023
	<i>R</i> ²	-0,9186	-0,0356	-0,5952	0,1806
	<i>MAPE</i>	21,9520	9,0154	10,1556	9,3725
WIG-Banki	<i>RMSE</i>	0,4186	0,0024	0,0027	0,0025
	<i>R</i> ²	-0,9484	-0,0551	-0,9668	-0,1504
	<i>MAPE</i>	25,1375	12,0665	13,3517	11,6328

Źródło: Opracowanie własne

Analizując wyniki uzyskane dla czwartego okresu i miesięcznego okna zmienności, należy zauważyć, że dla obu instrumentów najlepsze wyniki błędów bezwzględnych osiągnął model LSTM, natomiast najwyższy – i jako jedyny dodatni – współczynnik

determinacji dla spółki PKO uzyskał model GARCH-GRU. Dla wszystkich przypadków w indeksie wartości R^2 są bardzo niskie lub wręcz ujemne, co wskazuje na ograniczoną zdolność modeli do wyjaśniania zmienności w danych testowych na tym poziomie agregacji. Można więc stwierdzić, że mimo relatywnie dobrych wyników *MAPE*, trafność prognozowanych zmian w czasie była słaba.

OKRES 5, ZMIENNOŚĆ TYGODNIOWA

Tabela 33 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 5 przy 5-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	1,1741	0,0077	0,0055	0,0076
	<i>R²</i>	-0,2514	-0,0275	0,4647	0,0954
	<i>MAPE</i>	90,8178	73,4165	64,9331	76,6170
WIG-Banki	<i>RMSE</i>	0,9604	0,0071	0,0045	0,0066
	<i>R²</i>	-0,1800	-0,0842	0,5128	0,1226
	<i>MAPE</i>	80,5839	70,5206	50,8381	63,7875

Źródło: Opracowanie własne

W przypadku piątego okresu i 5-dniowego okna zmienności, wszystkie modele uzyskały relatywnie wysokie wartości błędów, co świadczy o dużych trudnościach w dokładnym odwzorowaniu krótkoterminowej zmienności w tym horyzoncie. Pomimo tego model XGBoost osiągnął zdecydowanie najwyższe wartości współczynnika determinacji dla PKO i indeksu sektorowego, nie jest to jednak przeważający argument za uznaniem tych modeli za dobre, przy tak wysokim poziomie błędów predykcji.

OKRES 5, ZMIENNOŚĆ DWUTYGODNIOWA

Tabela 34 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 5 przy 10-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	0,8146	0,0076	0,0031	0,0037
	<i>R²</i>	-0,0155	0,0364	0,7262	0,5932
	<i>MAPE</i>	33,0280	46,2476	20,1523	25,1667
WIG-Banki	<i>RMSE</i>	0,5683	0,0063	0,0025	0,0030
	<i>R²</i>	0,2217	0,0567	0,7066	0,5569
	<i>MAPE</i>	34,7406	39,4410	17,4207	20,9358

Źródło: Opracowanie własne

W analizowanym okresie piątym dla 10-dniowego okna zmienności najlepsze wyniki uzyskano w przypadku modelu XGBoost, który osiągnął zdecydowanie najwyższe wartości współczynnika determinacji dla PKO oraz dla WIG-Banki — przy jednocześnie najniższych wartościach błędów *RMSE* i *MAPE*. Pozostałe modele, mimo iż dla niektórych miar osiągały umiarkowanie dobre rezultaty, wyraźnie ustępowały skutecznością XGBoost w tym układzie danych.

OKRES 5, ZMIENNOŚĆ MIESIĘCZNA

Tabela 35 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 5 przy 20-dniowym oknie zmienności

		<i>GARCH</i>	<i>LSTM</i>	<i>XGBoost</i>	<i>GARCH-GRU</i>
PKO	<i>RMSE</i>	0,6064	0,0034	0,0018	0,0034
	<i>R²</i>	0,0799	0,0131	0,7405	0,7186
	<i>MAPE</i>	20,4646	20,6604	8,5999	15,9872
WIG-Banki	<i>RMSE</i>	0,4866	0,0048	0,0016	0,0028
	<i>R²</i>	0,0904	0,0128	0,6496	0,7328
	<i>MAPE</i>	21,2099	23,2191	10,3838	13,9820

Źródło: Opracowanie własne

W przypadku okresu czwartego i miesięcznego okna zmienności, modele XGBoost oraz GARCH-GRU wykazują zdecydowanie najwyższą skuteczność prognozowania — zarówno dla PKO, jak i dla WIG-Banki. Model XGBoost osiąga najwyższe wartości

współczynnika determinacji oraz najniższe wartości *RMSE* i *MAPE*. GARCH-GRU prezentuje zbliżoną jakość prognoz, zwłaszcza dla indeksu WIG-Banki. Pozostałe modele osiągają wyraźnie niższą efektywność predykcji w tym okresie i konfiguracji okna.

5.2. Porównanie wyników pracy z wnioskami z literatury przedmiotu

Wyniki uzyskane w niniejszej pracy są w dużej mierze zbieżne z ustaleniami innych badaczy zajmujących się prognozowaniem zmienności. Przykładowo w badaniu autorstwa Wei'a, Yang'a i Cui'a pt. *Integrated GRACH-GRU in Financial Volatility Forecasting*⁵³, model hybrydowy GARCH-GRU, choć zaprojektowany nieco inaczej niż w niniejszej pracy, gdyż wbudowuje komponent GARCH bezpośrednio w architekturę GRU; wyraźnie przewyższył model GARCH(1,1) oraz LSTM, osiągając niższe wartości błędów predykcji dla indeksów amerykańskich. Z kolei w pracy *Volatility Forecasting using GARCH-GRU Hybrid Models*⁵⁴ autorstwa Michańkowa, Kwiatkowskiego i Morajdy; w której zastosowano tożsamą wersję GARCH-GRU jak w niniejszej analizie, potwierdzono wyższą skuteczność tego modelu względem GARCH(1,1), szczególnie w warunkach zmiennych reżimów rynkowych. Natomiast badanie *Futures volatility forecasting based on big data analytics with incorporating an order imbalance effect*⁵⁵ autorstwa Ding'a, Cui'a i Zhang'a, choć porównuje model XGBoost z wariantem GARCH-jump, również wstępuje na znaczną przewagę modelu uczenia maszynowego. Warto jednak zaznaczyć, że wyniki empiryczne uzyskane w niniejszej pracy są bardziej zróżnicowane. Model GRACH-GRU wyraźnie zdominował pozostałe modele pod względem trafności prognoz, co może wynikać zarówno ze specyfikacji zastosowanej architektury, ale także cech charakterystycznych polskiego rynku kapitałowego, który podlega innym dynamikom niż rynki rozwinięte, przy czym przewaga ta nie była tak widoczna względem modelu XGBoost.

⁵³ J. Wei, S. Yang, Z. Cui, *Integrated GARCH-GRU in Financial Volatility Forecasting*, Stevens Institute of Technology 2022, s. 2-24.

⁵⁴ J. Michańków, Ł. Kwiatkowski, J. Morajda, *Combining Deep Learning and GARCH Models for Financial Volatility and Risk Forecasting*, "32nd International Conference On Information Systems Development" 2024, s. 1-25.

⁵⁵ S. Ding, T. Cui, Y. Zhang, *Futures volatility forecasting based on big data analytics with incorporating an order imbalance effect*, „International Review of Financial Analysis” 2022, nr 83, s. 1-11.

5.3. Wnioski końcowe

Analiza przeprowadzona na danych dotyczących spółki PKO Bank Polski oraz indeksu WIG-Banki, obejmujących pięć zróżnicowanych okresów rynkowych, potwierdza istotne różnice w zachowaniu i strukturze zmienności między oboma instrumentami. Dane dla indeksu charakteryzują się wyższym poziomem agregacji oraz większym wygładzeniem, co skutkowało mniejszą niestabilnością i lepszym dopasowaniem modeli opartych na technikach klasyfikacyjno-regresyjnych, takich jak XGBoost. Natomiast w przypadku spółki PKO, bardziej reaktywna i podatna na szoki charakterystyka zmienności sprawiała, że lepsze wyniki częściej uzyskiwały modele sekwencyjne i hybrydowe, w szczególności GARCH-GRU, który skutecznie uchwycił dynamiczne wzorce w danych.

Kolejny istotny wniosek dotyczy wpływu długości okna agregacji zmienności na skuteczność modeli prognostycznych. Można zaobserwować ogólną tendencję, zgodnie z którą w przypadku dłuższych okien (20-dniowych) modele wykazywały większą stabilność predykcji, a ich wyniki cechowały się wyższym współczynnikiem determinacji. Dłuższe okna zmienności, ze względu na efekt wygładzania krótkoterminowych fluktuacji, sprzyjały lepszemu odwzorowaniu struktury danych przez modele o bardziej uogólniającej charakterystyce, takie jak GARCH-GRU czy XGBoost.

Ostateczna analiza porównawcza z uwzględnieniem pięciu wyodrębnionych okresów rynkowych ukazuje istotny wpływ uwarunkowań makroekonomicznych na skuteczność poszczególnych modeli prognostycznych. Największa względna niestabilność – mierzona współczynnikiem zmienności – występowała w okresach IV i V, obejmujących odpowiednio pandemię COVID-19 oraz wojnę w Ukrainie i kryzys inflacyjny. Mimo iż dane z tych okresów były trudniejsze do modelowania, to właśnie wtedy model XGBoost osiągnął relatywnie najlepsze rezultaty, szczególnie w okresie V. Z kolei okres IV okazał się generalnie najtrudniejszy prognostycznie – wszystkie modele wykazywały ograniczoną trafność predykcji, choć częściowo skuteczność zachowały GARCH-GRU oraz XGBoost.

W okresie III, uznawanym za relatywnie stabilny gospodarczo, wyniki były bardziej wyrównane. Dla spółki PKO Bank Polski dominował model GARCH-GRU, natomiast dla indeksu WIG-Banki skuteczność rozkładała się równomiernie pomiędzy GARCH-GRU i XGBoost. W okresie II, obejmującym m.in. presję związaną z kredytami frankowymi i wprowadzeniem podatku bankowego, zdecydowaną dominację osiągał

model GARCH-GRU. W okresie I natomiast nie wyróżnił się jeden wyraźny lider — skuteczność predykcji była zróżnicowana i rozkładała się pomiędzy GARCH-GRU oraz XGBoost, zależnie od zbioru i horyzontu czasowego.

Model GARCH, mimo swojej popularności w literaturze klasycznej, nie spełnił oczekiwań prognostycznych w żadnym z okresów. Z kolei LSTM – choć w wybranych konfiguracjach osiągał umiarkowanie dobre wyniki – nie wykazał się stabilną skutecznością. Można przypuszczać, że sieci rekurencyjne tego typu wymagają dłuższych, jednolitych sekwencji danych oraz większej liczby obserwacji, co w warunkach fragmentaryzacji czasowej mogło ograniczyć ich efektywność.

Podsumowanie

Przeprowadzona analiza wskazuje, że modelowanie zmienności finansowej, szczególnie w krótkim horyzoncie czasowym, pozostaje wysoko złożonym zadaniem obciążonym znacznym ryzykiem błędu. Zmienność cechuje się dużym poziomem losowości i znaczną podatnością na szoki rynkowe, co znacząco utrudnia uzyskanie spójnych i uniwersalnych reguł prognostycznych. Z perspektywy badawczej największy potencjał ujawniło podejście hybrydowe, czyli model GARCH-GRU. Równocześnie, model XGBoost, reprezentujący rodzinę uczenia gradientowego za pomocą drzew decyzyjnych, również wykazał stabilność predykcyjną w licznych układach danych. Wyniki niniejszej pracy sugerują, że tego typu architektury mogą stanowić istotny kierunek dalszych badań. Również istotnym wnioskiem płynącym z analizy jest znaczenie kontekstu czasowego. Wysoka niestabilność rynkowa osłabiała skuteczność niektórych modeli, podczas gdy inne lepiej radziły sobie z fluktuacjami, wykazując większą odporność.

Bibliografia

- [1] Barczyk R., Morfologia cykli koniunkturalnych i cykli bankowych w gospodarce polskiej w latach 2000-2017, „Prace naukowe Uniwersytetu Ekonomicznego we Wrocławiu” 2018, nr 509, s. 33-45,
- [2] Borsuk M., Wpływ Bazylei III na pozycję kapitałową polskich banków, (w:) „Studia z Zakresu Prawa, Administracji i Zarządzania” 2015, t.8, s. 114-128,
- [3] Chen T., Guestrin C., XGBoost: A Scalable Tree Boosting System, (w:) „Proceedings of the 22nd AVM SIGDD International Conference on Knowledge Discovery and Data Mining” 2016,
- [4] Ding S., Cui T., Zhang Y., Futures volatility forecasting based on big data analytics with incorporating an order imbalance effect, „International Review of Financial Analysis” 2022, nr 83, s. 1-11,
- [5] Friedman J., Hastie T., Tibisharani R., Additive Models, Trees, and Related Methods, (w:) „The Elements of Statistical Learning: Data Mining, Inference and Prediction”, Springer, Nowy Jork 2008,
- [6] Gemzik-Salwach A., Skutki regulacji Bazylei III dla sektora bankowego i gospodarki, „Annales Universitatis Mariae Curie-Skłodowska Lublin-Polonia” t. 46, nr 4, 2012, s. 199-210,
- [7] Geron A., Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow, Helion, Gliwice 2020,
- [8] Goodfellow I., Bengio Y., Courville A., Deep Learning, Springer, 2016,
- [9] Hajirahimi Z., Khashei M., Hybridization of hybrid structures for time series forecasting: a review, „Artificial Intelligence Review” 2022, nr 56, s. 1201-1261,
- [10] Hochreiter S., Schmidhuber J., Long Short-Term Memory, „Neural Computation” 1997, t.9, nr 8, s. 1-32,
- [11] Liu R., Jiang Y., Lin J., Forecasting the Volatility of Specific Risk for Stocks with LSTM, „Proceedings of the International Conference on Identification, Information and Knowledge in the Internet of Things” 2021, nr 202, s. 111-114,
- [12] Michańków J., Kwiatkowski Ł., Morajda J., Combining Deep Learning and GARCH Models for Financial Volatility and Risk Forecasting, “32nd International Conference On Information Systems Development” 2024,
- [13] Poon S. H., A Practical Guide to Forecasting Financial Market Volatility, Wiley, Chichester 2005,

- [14] Pyka I., Nowe regulacje bankowe a stabilność finansowa polskiego sektora bankowego, „Studia Ekonomiczne” 2014, nr 186, s. 196-206,
- [15] Sahiner M., Forecasting volatility in Asian financial markets: Evidence from recursive and rolling window methods, „Journal of Economics, Finance and Accounting Studies” 2022, t. 2, nr 157, s. 1-74,
- [16] Sharma S., Aggrwal V., Comparison of linear and non-linear GARCH models for forecasting volatility of select emerging countries, „Journal of Advances in Management Research” 2020, s. 1-23,
- [17] Taylor S. J., Asset Price Dynamics, Volatility, and Prediction, Princeton University Press, Princeton 2011,
- [18] Tsay R. S., Analysis of Financial Time Series, Wiley, Hooboken 2010,
- [19] Wei J., Yang S., Cui Z., Integrated GARCH-GRU in Financial Volatility Forecasting, Stevens Institute of Technology 2022, s. 1-24,
- [20] Xiao L., Aydemir A., Volatility modelling and forecasting in finance, (w:) Forecasting Volatility in the Financial Markets, red. S. Satchell, J. Knight, Butterworth-Heinemann, Oxford 2007.

Źródła internetowe

- [1] ZasadyForex, *Co wpływa na zmienność na rynkach kapitałowych?*, ZasadyForex.pl, <https://zasadyforex.pl/co-wplywa-na-zmienosc-na-rynkach-kapitalowych/>,
- [2] GPW karta indeksu <https://gpwbenchmark.pl/karta-indeksu?isin=PL9999999904>,
- [3] GPW karta indeksu [GPW Benchmark - Karta indeksu](#),
- [4] GPW karta indeksu [GPW Benchmark - Karta indeksu](#),
- [5] [R-Squared: Definition, Calculation, and Interpretation](#),
- [6] [Hyperparameter Tuning - GeeksforGeeks](#),
- [7] [A Guide to LSTM Hyperparameter Tuning for Optimal Model Training | by HIYA CHATTERJEE | Medium](#)
- [8] [XGBoost Parameters Tuning: A Complete Guide with Python Codes](#)

Spis Rysunków

Rysunek 1 Zmienność realizowana dla indeksu WIG-Banki obliczana w ruchomych oknach 5-, 10- i 20-dniowych w pięciu wyodrębnionych okresach rynkowych.	19
Rysunek 2 Zmienność realizowana dla PKO Bank Polski obliczana w ruchomych oknach 5-, 10- i 20-dniowych w pięciu wyodrębnionych okresach rynkowych.	21
Rysunek 3 Pojedyncza komórka sieci LSTM.....	26
Rysunek 4 Bramka zapomnienia, część Rysunku 1.....	28
Rysunek 5 Bramka wejścia oraz bramka główna, część Rysunku 1.	28
Rysunek 6 Bramka wyjścia, część Rysunku 1.....	29
Rysunek 7 Ramowy model szeregowego CBH	32
Rysunek 8 Pojedyncza komórka sieci GRU	33
Rysunek 9 Struktura modelu GARCH-GRU.....	35
Rysunek 10 Prognozy GARCH(1,1) jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) dla spółki PKO.	38
Rysunek 11 Prognozy GARCH(1,1) jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) indeksu WIG-Banki.	39
Rysunek 12 Prognozy LSTM jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) spółki PKO.	44
Rysunek 13 Prognozy LSTM jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) indeksu WIG-Banki.	45
Rysunek 14 Prognozy XGBoost jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) spółki PKO.	51
Rysunek 15 Prognozy XGBoost jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) indeksu WIG-Banki.	52
Rysunek 16 Prognozy GARCH-GRU jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023)spółki PKO.	58

Rysunek 17 Prognozy GARCH-GRU jednodniowej zmienności w przód wygenerowane na podstawie 5-, 10- i 20-dniowego okna, osobno dla pięciu wyróżnionych okresów rynkowych (2013–2023) indeksu WIG-Banki.	59
---	----

Spis tabel

Tabela 1 Skład indeksu WIG-Banki	13
Tabela 2 Statystyki opisowe zmienności realizowanej (PKO Bank Polski i WIG-Banki) w podziale na okresy rynkowe i długości okien	22
Tabela 3 Najlepsze konfiguracje hiperparametrów modeli LSTM dla spółki PKO Bank Polski w oknie 5-dniowym	41
Tabela 4 Najlepsze konfiguracje hiperparametrów modeli LSTM dla spółki PKO Bank Polski w oknie 10-dniowym	42
Tabela 5 Najlepsze konfiguracje hiperparametrów modeli LSTM dla spółki PKO Bank Polski w oknie 20-dniowym	42
Tabela 6 Najlepsze konfiguracje hiperparametrów modeli LSTM dla indeksu WIG-Banki w oknie 5-dniowym.....	42
Tabela 7 Najlepsze konfiguracje hiperparametrów modeli LSTM dla indeksu WIG-Banki w oknie 10-dniowym.....	43
Tabela 8 Najlepsze konfiguracje hiperparametrów modeli LSTM dla indeksu WIG-Banki w oknie 20-dniowym.....	43
Tabela 9 Najlepsze konfiguracje hiperparametrów modeli XGBoost dla spółki PKO Bank Polski w oknie 5-dniowym.....	47
Tabela 10 Najlepsze konfiguracje hiperparametrów modeli XGBoost dla spółki PKO Bank Polski w oknie 10-dniowym.....	48
Tabela 11 Najlepsze konfiguracje hiperparametrów modeli XGBoost dla spółki PKO Bank Polski w oknie 20-dniowym.....	48
Tabela 12 Najlepsze konfiguracje hiperparametrów modeli XGBoost dla indeksu WIG-Banki w oknie 5-dniowym.....	49
Tabela 13 Najlepsze konfiguracje hiperparametrów modeli XGBoost dla indeksu WIG-Banki w oknie 10-dniowym.....	49
Tabela 14 Najlepsze konfiguracje hiperparametrów modeli XGBoost dla indeksu WIG-Banki w oknie 20-dniowym.....	50
Tabela 15 Najlepsze konfiguracje hiperparametrów modeli GARCH-GRU dla spółki PKO Bank Polski w oknie 5-dniowym.....	54
Tabela 16 Najlepsze konfiguracje hiperparametrów modeli GARCH-GRU dla spółki PKO Bank Polski w oknie 10-dniowym.....	55

Tabela 17 Najlepsze konfiguracje hiperparametrów modeli GARCH-GRU dla spółki PKO Bank Polski w oknie 20-dniowym.....	55
Tabela 18 Najlepsze konfiguracje hiperparametrów modeli GARCH-GRU dla indeksu WIG-Banki w oknie 5-dniowym	56
Tabela 19 Najlepsze konfiguracje hiperparametrów modeli GARCH-GRU dla indeksu WIG-Banki w oknie 10-dniowym	56
Tabela 20 Najlepsze konfiguracje hiperparametrów modeli GARCH-GRU dla indeksu WIG-Banki w oknie 20-dniowym	57
Tabela 21 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 1. przy 5-dniowym oknie zmienności	61
Tabela 22 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 1. przy 10-dniowym oknie zmienności	61
Tabela 23 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 1 przy 20-dniowym oknie zmienności	62
Tabela 24 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 2 przy 5-dniowym oknie zmienności	62
Tabela 25 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 2 przy 10-dniowym oknie zmienności	63
Tabela 26 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 2 przy 20-dniowym oknie zmienności	64
Tabela 27 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 3 przy 5-dniowym oknie zmienności	64
Tabela 28 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 3 przy 10-dniowym oknie zmienności	65
Tabela 29 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 3 przy 20-dniowym oknie zmienności	65
Tabela 30 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 4 przy 5-dniowym oknie zmienności	66
Tabela 31 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 4 przy 10-dniowym oknie zmienności	67
Tabela 32 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 4 przy 20-dniowym oknie zmienności	67
Tabela 33 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 5 przy 5-dniowym oknie zmienności	68

Tabela 34 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 5 przy 10-dniowym oknie zmienności 69

Tabela 35 Miary jakości prognoz dla modeli prognostycznych dla spółki PKO Bank Polski oraz indeksu WIG-Banki w okresie 5 przy 20-dniowym oknie zmienności 69

Spis załączników

[1] https://github.com/Zuzia416553/volatility_prediction